Sprawozdanie - Lista 1

Analiza szeregów czasowych

Dominik Kowalczyk i Mateusz Martynów

2025-11-16

Spis treści

1 Zadanie 3a - Testowanie białoszumowości: testy graficzne i formalne 2
1.1 Opis zagadnienia 2
1.2 Opis eksperymentów i analiz 2
1.3 Wyniki 3

2 Zadanie 3b - Testowanie białoszumowości: symulacje komputerowe 9
2.1 Opis zagadnienia 9
2.2 Opis eksperymentów i analiz 9
2.3 Wyniki 10

3 Zadanie 4 14
3.1 Analiza podstawowych danych szeregu 14
3.2 Porównanie wyników dla poznanych metod dekompozycji szeregu czasowego 17
3.3 Weryfikacja dopasowania poszczególnych modeli 24
3.4 Wpływ wyboru parametrów na wyniki danej metody dekompozycji 27
3.5 Zastosowanie transformacji Boxa-Coxa do poprawy jakości dopasowania modeli dekompozycji 29
3.6 Porównanie metod eliminacji składowych (dekompozycja vs. różnicowanie danych 33

1 Zadanie 3a - Testowanie białoszumowości: testy graficzne i formalne

1.1 Opis zagadnienia

Celem analizy jest weryfikacja, czy dany szereg czasowy może być uznany za biały szum - czyli proces nieskorelowany, o stałej wariancji i zerowej wartości oczekiwanej. Testy białoszumowości pozwalają ocenić, czy w danych występują zależności czasowe. Zastosujemy dwa podejścia:

1. **Graficzne testowanie białoszumowości**, oparte na wykresie próbkowej funkcji autokorelacji (ACF). Jeśli wszystkie współczynniki autokorelacji $\hat{\rho}(h)$ (dla $h > 0$) mieszczą się w przedziale ufności:

$$\left[-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}}\right],$$

to nie ma podstaw do odrzucenia hipotezy, że szereg jest białym szumem.

2. **Formalne testy statystyczne**, takie jak test **Boxa-Pierce'a** oraz **Ljunga-Boxa**, oceniają łączną siłę autokorelacji do określonego rzędu. Ich statystyki mają postać:

- test Boxa-Pierce'a:

$$Q_{BP} = n \sum_{k=1}^{h} \hat{\rho}(k)^2$$

- test Ljunga-Boxa:

$$Q_{LB} = n(n+2) \sum_{k=1}^{h} \frac{\hat{\rho}(k)^2}{n-k}$$

  Obie statystyki mają asymptotycznie rozkład χ^2_h, gdzie h to maksymalny rząd testowanej autokorelacji.

1.2 Opis eksperymentów i analiz

Przeprowadzimy testy dla czterech typów szeregów czasowych:

- Gaussowski biały szum: $Z_t \sim \mathcal{WN}(0, 1)$,
- Proces MA(1): $X_t = Z_t + \theta Z_{t-1}$,
- Proces z trendem liniowym: $X_t = at + Z_t$,
- Biały szum i.i.d. o rozkładzie wykładniczym: $Z_t \sim \mathcal{E}(1)$.

Dla każdego przypadku:

- narysujemy wykres realizacji szeregu, wykres ACF (korelogram) z przedziałami ufności oraz wykres rozrzutu między dwoma kolejnymi obserwacjami szeregu (test graficzny),
- przeprowadzimy testy Ljunga-Boxa i Boxa-Pierce'a na poziomie istotności $\alpha = 0.05$.

1.3 Wyniki

W celu realizacji obu podejść do testowania białoszumowości, zaimplementowaliśmy dwie funkcje `test_graf()` oraz `test_formalny()`. Pierwsza z nich bazuje na próbkowej funkcji autokorelacji ACF i odwzorowuje reguły graficznego testu białoszumowości: sprawdza, czy co najmniej 95% autokorelacji dla opóźnień $h = 1, ..., h_{max}$ mieści się w asymptotycznym przedziale ufności $\pm\frac{1{,}96}{\sqrt{n}}$ oraz czy żadna z nich nie przekracza poziomu $\pm 3\sigma$, gdzie $\sigma = \frac{1}{\sqrt{n}}$. Na tej podstawie zwraca wartość 1, gdy brak podstaw do odrzucenia hipotezy H_0 o białym szumie, oraz 0 w przeciwnym przypadku.

Funkcja `test_formalny` implementuje z kolei formalne testy Boxa-Pierce'a i Ljunga-Boxa, korzystając z wbudowanej funkcji `Box.test()`. Dla zadanego szeregu oraz wybranego typu testu porównuje p-value z poziomem istotności α i zwraca 1, jeżeli nie ma podstaw do odrzucenia hipotezy H_0, oraz 0, gdy hipoteza H_0 zostaje odrzucona.

Obie funkcje zostały napisane tak, aby przyjmować zarówno pojedynczy wektor obserwacji, jak i macierz realizacji (w tym drugim przypadku test jest automatycznie wykonywany osobno dla każdej kolumny, co będzie wykorzystane w części symulacyjnej w podpunkcie b)

1.3.1 Gaussowski biały szum

Jako pierwszy przykład rozważono realizację klasycznego gaussowskiego białego szumu, czyli szeregu złożonego z niezależnych zmiennych losowych o rozkładzie $\mathcal{N}(0, 1)$. Taki proces zgodnie z definicją nie zawiera żadnych zależności czasowych. Poniżej przedstawiamy wykres szeregu, jego próbkową funkcję autokorelacji oraz wyniki przeprowadzonych testów graficznych i formalnych.

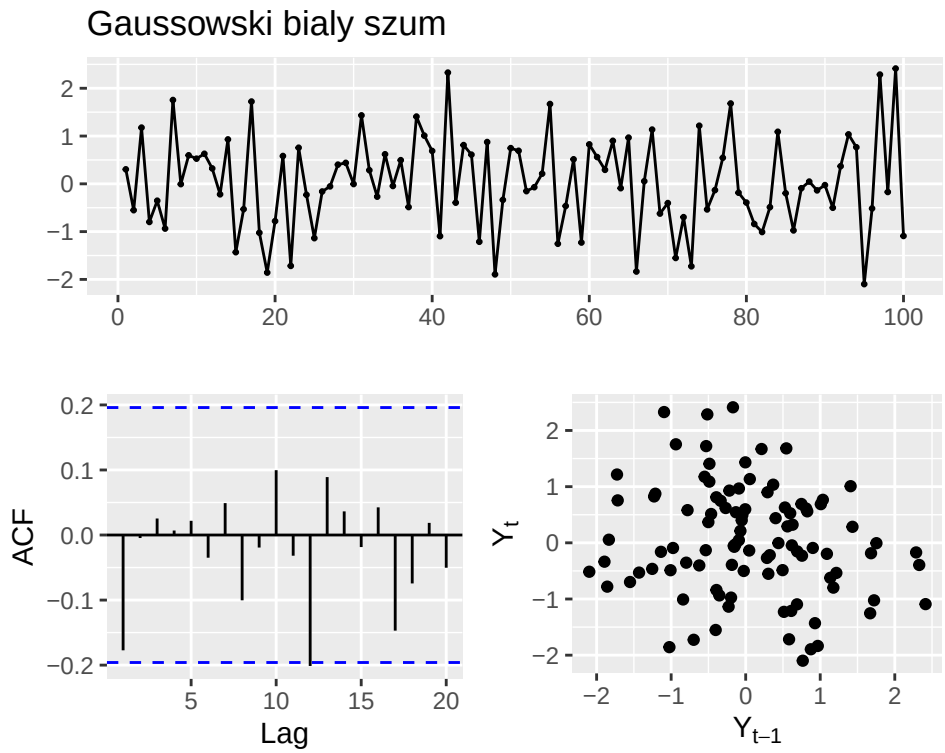

Rysunek 1: Graficzna analiza realizacji gaussowskiego białego szumu: wykres szeregu czasowego (górny panel), funkcja autokorelacji ACF (lewy dolny panel) oraz wykres rozrzutu Y_t względem Y_{t-1} (prawy dolny panel)

Wyniki:

- Funkcja tesu graficznego zwraca: 1,
- p-value dla testu Boxa-Pierce'a: 0.9179,
- p-value dla testu Ljungi-Boxa: 0.8212.

Wnioski:

Analizowany szereg to realizacja gaussowskiego białego szumu $Z_t \sim \mathcal{WN}(0, 1)$.

Na podstawie wykresu 1 ACF można zauważyć, że wszystkie wartości autokorelacji $\hat{\rho}(h)$ dla $h > 0$ mieszczą się w przedziale ufności:

$$\left[-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}}\right],$$

oznaczonym na wykresie przerywaną, niebieską linią, co wskazuje, że nie występują istotne zależności czasowe - szereg jest zgodny z definicją białego szumu. Bezpośrednio potwierdza to także funkcja testu graficznego, która po zliczeniu liczby obserwacji wystających poza granice przedziału ufności oraz stwierdzeniu, że zadna z tych obserwacji nie wystaje znacząco, zwróciła 1 oznaczającą przyjęcie hipotezy H_0 o białoszumowości.

Wyniki testów formalnych również to potwierdzają: Obie wartości p-value są znacznie większe od poziomu istotności $\alpha = 0.05$, więc nie ma podstaw do odrzucenia hipotezy zerowej o białym szumie. Zatem, zarówno analiza graficzna, jak i testy statystyczne potwierdzają, że analizowany szereg czasowy jest realizacją procesu białego szumu.

1.3.2 Proces MA(1)

Kolejny przykład stanowi realizacja procesu średniej ruchomej rzędu 1, będącego prostym modelem stacjonarnym o krótkiej pamięci. Proces ten powstaje poprzez dodanie do białego szumu jego przesuniętej kopii pomnożonej przez parametr θ, co wprowadza zależność między sąsiednimi obserwacjami. Dzięki temu model MA(1) jest naturalnym przykładem szeregu, który nie jest białym szumem, a więc powinien zostać odrzucony zarówno przez test graficzny, jak i formalne testy.

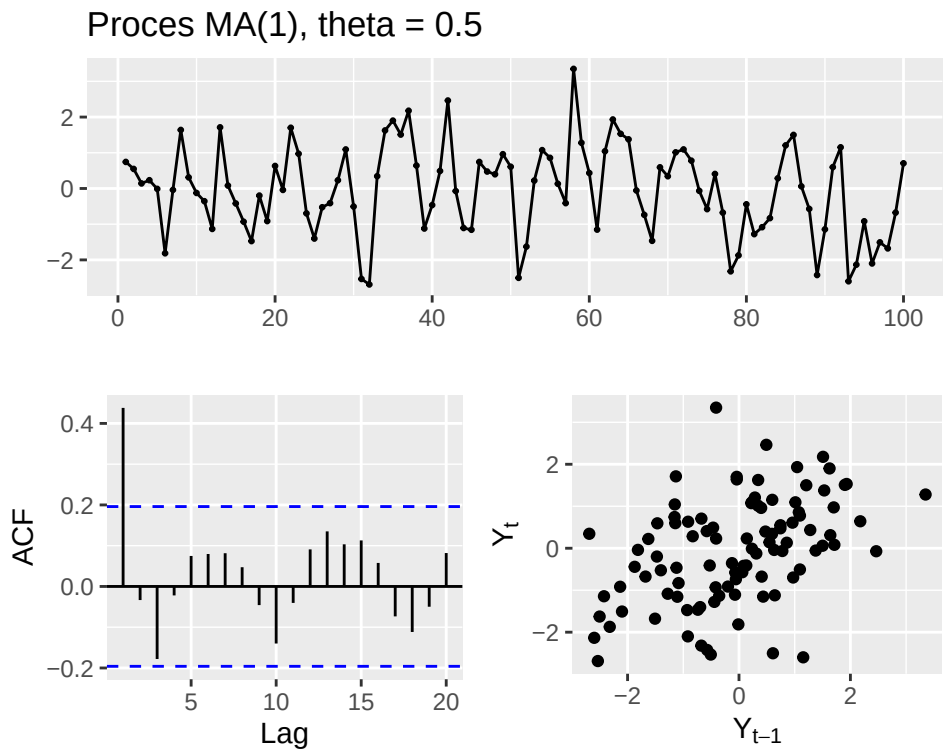

Rysunek 2: Graficzna analiza realizacji procesu MA(1): wykres szeregu czasowego (górny panel), funkcja autokorelacji ACF (lewy dolny panel) oraz wykres rozrzutu Y_t względem Y_{t-1} (prawy dolny panel)

Wyniki:

- Funkcja tesu graficznego zwraca 0,
- p-value dla testu Boxa-Pierce'a: 0.0346,
- p-value dla testu Ljunga-Boxa: 0.0121.

Wnioski:

Pierwszy warunek graficznego testu białoszumowości - dotyczący częstości wpadania autokorelacji do przedziałów istotności - można uznać w przybliżeniu za spełniony. Jak widzimy jednak na wykresie 2 autokorelacja dla $h = 1$ wyraźnie przekracza przedziały ufności:

$$\left[-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}}\right],$$

co świadczy o obecności zależności czasowych i wskazuje, że nie mamy do czynienia z realizacją białego szumu. Potwierdza to także funkcja testu graficznego, która zwróciła 0 oznaczające odrzucenie hipotezy o białoszumowości. Wyniki testów formalnych mogą sugerować białoszumowość ze względu na dość wysokie wartości p-value, jednak przekroczenie granicy istotności przez $\hat{\rho}(1)$ jest wystarczającym dowodem na odrzucenie hipotezy o białym szumie.

1.3.3 Proces z trendem liniowym

Kolejny przykład dotyczy szeregu, który oprócz składnika losowego zawiera deterministyczny trend liniowy. Obecność trendu powoduje systematyczny wzrost wartości w czasie i prowadzi do silnej autokorelacji obserwacji, mimo że składnik losowy jest białym szumem. Taki proces powinien zostać jednoznacznie odrzucony jako biały szum.

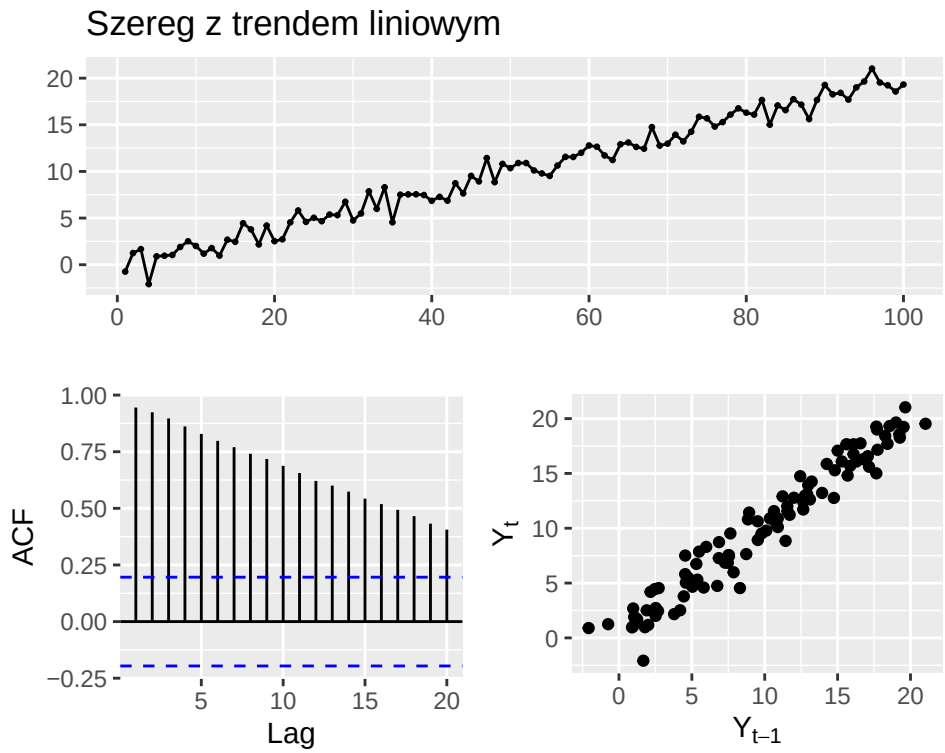

Rysunek 3: Graficzna analiza realizacji procesu z deterministycznym trendem liniowym: wykres szeregu czasowego (górny panel), funkcja autokorelacji ACF (lewy dolny panel) oraz wykres rozrzutu Y_t względem Y_{t-1} (prawy dolny panel)

Wyniki:

- Funkcja tesu graficznego zwraca 0,
- p-value dla testu Boxa-Pierce'a: 0,
- p-value dla testu Ljunga-Boxa: 0.

Wnioski:

Analizowany szereg zawiera deterministyczny trend liniowy, co powoduje systematyczny wzrost wartości w czasie. Wykres 3 szeregu wyraźnie pokazuje nielosową strukturę, a na wykresie ACF wiele wartości przekracza przedział ufności:

$$\left[-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}}\right],$$

co wskazuje na obecność silnych zależności czasowych.

Funkcja testu graficznego zwraca 0, co wskazuje, że powinniśmy odrzucić hipotezę H_0 o białoszumowości.

Wyniki testów formalnych pokazują, że obie wartości są znacznie mniejsze niż poziom istotności $\alpha = 0.05$, co prowadzi do odrzucenia hipotezy o białym szumie.

Zatem obecność trendu liniowego sprawia, że szereg nie spełnia warunku białoszumowości, mimo że zakłócenie Z_t jest realizacją białego szumu.

1.3.4 Biały szum o rozkładzie wykładniczym

Dodatkowo przetestowaliśmy realizację białego szumu pochodzącą z rozkładu wykładniczego $\mathcal{E}(1)$. Choć zmienne mają rozkład silnie asymetryczny i dodatnio skośny, to wciąż są niezależne, a więc proces ten powinien spełniać hipotezę białoszumowości. Testy powinny zwrócić wynik analogiczny do przypadku białego szumu normalnego.

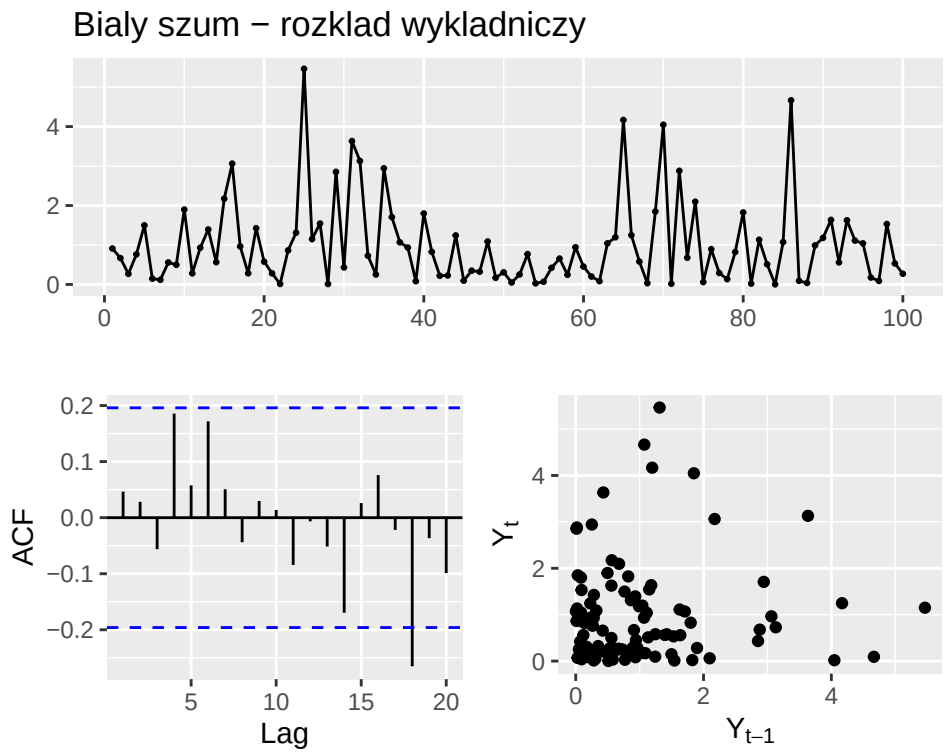

Rysunek 4: Graficzna analiza realizacji białego szumu o rozkładzie wykładniczym: wykres szeregu czasowego (górny panel), funkcja autokorelacji ACF (lewy dolny panel) oraz wykres rozrzutu Y_t względem Y_{t-1} (prawy dolny panel)

Wyniki:

- Funkcja tesu graficznego zwraca 1,
- p-value dla testu Boxa-Pierce'a: 0.3455,
- p-value dla testu Ljunga-Boxa: 0.1369.

Wnioski:

Analizowany szereg stanowi realizację białego szumu, w którym zmienne losowe pochodzą z rozkładu wykładniczego $\mathcal{E}(1)$. Choć rozkład ten jest silnie asymetryczny i dodatnio skośny, to brak zależności czasowych sprawia, że proces powinien spełniać własności białego szumu.

Na wykresie 4 szeregu czasowego nie widać żadnej regularnej struktury, a próbkowa funkcja autokorelacji dla opóźnień $h \geq 1$ praktycznie w całości mieści się w asymptotycznym przedziale ufności:

$$\left[-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}}\right],$$

co oznacza brak istotnych zależności pomiędzy obserwacjami. Funkcja testu graficznego zwraca wartość 1, co wskazuje na brak podstaw do odrzucenia hipotezy H_0 o białoszumowości. Wyniki formalnych testów Boxa-Pierce'a i Ljunga-Boxa potwierdzają te obserwacje: obie wartości p-value są wyraźnie większe od poziomu istotności $\alpha = 0.05$, co również prowadzi do nieodrzucenia hipotezy H_0. Zatem zarówno test graficzny, jak i oba formalne testy statystyczne potwierdzają, że mimo asymetrii rozkładu szeregu, proces ten zachowuje własności białego szumu.

1.3.5 Podsumowanie

W tej części przeanalizowaliśy działanie testu graficznego oraz testów formalnych Boxa-Pierce'a i Ljunga-Boxa na pojedynczych realizacjach różnych szeregów czasowych. Dla białego szumu normalnego wszystkie metody poprawnie nie odrzucały hipotezy H_0, natomiast dla procesów z autokorelacją (MA(1)) lub strukturą deterministyczną (trend) zarówno testy formalne, jak i analiza ACF wskazywały wyraźne odstępstwa od białoszumowości. Z kolei dla białego szumu o rozkładzie wykładniczym wyniki również potwierdziły brak autokorelacji. Podsumowując, test graficzny dobrze sprawdza się jako szybka diagnoza obecności zależności czasowych, natomiast testy formalne stanowią bardziej obiektywne narzędzie oceny białoszumowości.

2 Zadanie 3b - Testowanie białoszumowości: symulacje komputerowe

2.1 Opis zagadnienia

Celem tej części jest symulacyjne porównanie dwóch podejść do testowania białoszumowości: testu graficznego opartego na próbkowej funkcji autokorelacji oraz formalnych testów Boxa-Pierce'a i Ljunga-Boxa. Interesuje nas, jak często poszczególne testy poprawnie odrzucają lub nie odrzucają hipotezy H_0 o białym szumie w różnych sytuacjach:

- dla różnych rozkładów
- różnej długości szeregów
- różnego wyboru maksymalnego opóźnienia
- dla procesów, które nie są białym szumem.

2.2 Opis eksperymentów i analiz

W eksperymentach symulacyjnych wygenerujemy wielokrotne realizacje (o liczbie powtórzeń $R \in \{100, 500, 1000\}$ szeregów czasowych o długości $n \in \{20, 50, 100\}$. Rozważymy trzy

różne rozkłady dla szumu i.i.d.: normalny $\mathcal{N}(0,1)$, Cauchy'ego $\mathcal{C}(0,1)$ oraz dyskretny rozkład Bernoulliego $\mathcal{B}\{0,1\}$. Dodatkowo przeanalizujemy szeregi, które nie są białym szumem: proces MA(1) o niewielkiej korelacji $\theta = 0.5$, błądzenie losowe, szum i.i.d. z trendem liniowym oraz szum i.i.d. z deterministyczną sezonowością. Dla każdej kombinacji modelu, długości szeregu, liczby powtórzeń oraz maksymalnego opóźnienia h_{max} (rozważymy bardzo małe opóźnienie $h_{max} = 1$, $h_{max} = min(25, \lfloor n/4 \rfloor)$ oraz większe opóźnienie $h_{max} = \lfloor n/2 \rfloor$) obliczymy częstość odrzucenia hipotezy H_0 przez test graficzny oraz testy Boxa-Pierce'a i Ljunga-Boxa.

2.3 Wyniki

Dla każdego scenariusza wygenerujemy wiele realizacji danych, a następnie dla każdej realizacji ocenimy, czy dany test odrzuca hipotezę zerową o białoszumowości. Uwzględniliśmy siedem typów szeregów czasowych:

- BS_norm - biały szum o rozkładzie normalnym $\mathcal{N}(0,1)$
- BS_cauchy - biały szum o rozkłdzie Cauchy'ego $\mathcal{C}(0,1)$
- BS_ber - biały szum dyskretny z rozkładu Bernoulliego $\mathcal{B}\{0,1\}$
- MA1 - proces średniej ruchomej rzędu 1 z parametrem $\theta = 0.5$
- BL - błądzenie losowe
- trend - biały szum z liniowym trendem deterministycznym
- sezon - biały szum z dodaną sezonowością sinusoidalną

Dla każdego modelu zdefiniujemy osobną funkcję generującą realizacje szeregu. Dla każdej kombinacji parametrów opisanych w poprzedniej sekcji wygenerujemy macierz realizacji o wymiarach $n \times R$. Następnie:

- funkcja `test_graf()` będzie zwracała 0 lub 1 w zależności od tego, czy test graficzny odrzucił hipotezę H_0
- funkcja `test_formalny()` będzie obliczała wyniki testów Box-Pierce'a oraz Ljunga-Boxa.

Dla każdej konfiguracji obliczymy częstość odrzucenia hipotezy zerowej,

$$\hat{p} = \frac{1}{R} \sum_{i=1}^{R} \mathbf{1}\{H_0 \text{ odrzucono w próbie } i\}$$

co pozwala porównać:

- moc testów w sytuacjach, gdy dane nie są białym szumem,
- poziom istotności testów przy danych zgodnych z założeniami białego szumu.

Wszystkie wyniki zbierzemy w jednej ramce danych, a następnie wybierzemy z niej mniejsze tabele do analizy wpływu poszczególnych parametrów.

2.3.1 Wpływ długości szeregu n na częstość odrzucenia H_0

Tabela 1: Wpływ długości szeregu n na częstość odrzucenia H0 (model: BS_norm, R = 1000, h.max = h_graniczne).

model	n	ile_powtorz	h.max	graf_odrz	bp_odrz	lb_odrz
BS_norm	20	1000	5	0.113	0.019	0.054
BS_norm	50	1000	12	0.317	0.026	0.062
BS_norm	100	1000	25	0.222	0.027	0.084

Wnioski:

Wyniki w tabeli 1 pokazują, że częstość odrzucenia hipotezy H_0 przez test graficzny rośnie wraz z długością szeregu. Dla $n = 20$ jest ona równa 0.113, natomiast dla $n = 50$ wzrasta do 0.317, co wskazuje na większą podatność testu graficznego na przypadkowe przekroczenia granic ACF w dłuższych próbach. Testy formalne są znacznie stabilniejsze. Dla testu Boxa-Pierce'a wartości wynoszą odpowiednio 0.019, 0.026 i 0.027, a dla testu Ljunga-Boxa 0.054, 0.062, 0.084. Oznacza to, że testy formalne dobrze kontrolują poziom istotności, podczas gdy test graficzny jest bardziej zmienny, szczególnie dla krótkich szeregów.

2.3.2 Wpływ maksymalnego opóźnienia h_{max} na częstość odrzucenia H_0

Tabela 2: Wpływ wyboru h.max na częstość odrzucenia H0 (model: BS_norm, n = 100, R = 1000).

model	n	ile_powtorz	h.max	graf_odrz	bp_odrz	lb_odrz
BS_norm	100	1000	1	0.047	0.047	0.049
BS_norm	100	1000	25	0.222	0.027	0.084
BS_norm	100	1000	50	0.135	0.009	0.109

Wnioski:

Wyniki w tabeli 2 pokazują, że wybór h_{max} wyraźnie wpływa na zachowanie testu graficznego. Dla bardzo małego opóźnienia $h_{max} = 1$ zęstość odrzucenia wynosi tylko 0.047, natomiast dla wartości granicznej $h_{max} = 25$ rośnie do 0.222, co oznacza większą szansę przypadkowego przekroczenia granic ACF przy większej liczbie testowanych opóźnień. Testy formalne wykazują mniejszą wrażliwość na wybór h_{max}. Częstości odrzuceń w teście Boxa-Pierce'a zmieniają się od 0.047 do 0.009, a w teście Ljunga-Boxa od 0.049 do 0.109. Oznacza to, że testy formalne pozostają stabilne względem wyboru h_{max}, natomiast test graficzny staje się mniej dokładny, gdy analizujemy większą liczbę opóźnień.

2.3.3 Wpływ różnych rozkładów na częstość odrzucenia H_0

Tabela 3: Porównanie różnych rozkładów białego szumu (n = 100, h.max = 25, R = 1000).

model	n	ile_powtorz	h.max	graf_odrz	bp_odrz	lb_odrz
BS_norm	100	1000	25	0.222	0.027	0.084
BS_cauchy	100	1000	25	0.229	0.005	0.017
BS_ber	100	1000	25	0.224	0.027	0.082

Wnioski:

Porównanie trzech rozkładów białego szumu i.i.d. pokazuje, że test graficzny daje podobne wyniki niezależnie od rozkładu: wartości, które możemy zaobserwować w tabeli 3 mieszczą się w przedziale od 0.222 do 0.224, co sugeruje, że metoda wizualna reaguje głównie na losowe wahania ACF, a nie na właściwości rozkładu. Testy formalne wykazują większą wrażliwość na rozkład. W szczególności rozkład Cauchy'ego daje najniższe częstości odrzucenia: test Boxa-Pierce'a zwraca 0.005, a Ljunga-Boxa 0.017, co wynika z bardzo dużej zmienności wartości i braku skończonej wariancji. W przypadku białego szumu Bernoulliego wyniki są zbliżone do normalnego - np. 0.082 i 0.084. Oznacza to, że dla rozkładów o skończonej wariancji testy formalne zachowują się stabilnie, natomiast dla rozkładu Cauchy'ego mogą mieć obniżoną moc.

2.3.4 Wpływ różnych procesów niebędących białym szumem na częstość odrzucenia H_0

Tabela 4: Częstość odrzucenia H0 dla modeli z autokorelacją lub strukturą deterministyczną (n = 100, h.max = 25, R = 1000).

model	n	ile_powtorz	h.max	graf_odrz	bp_odrz	lb_odrz
MA1	100	1000	25	0.953	0.55	0.69
BL	100	1000	25	1.000	1.00	1.00
trend	100	1000	25	1.000	1.00	1.00
sezon	100	1000	25	1.000	1.00	1.00

Wnioski:

Jak możemy zauważyć w tabeli 4 wszystkie rozważane procesy, które nie są białym szumem, są prawidłowo rozpoznawane przez testy - częstości odrzucenia hipotezy H_0 są bardzo wysokie. Dla procesu MA(1) test graficzny odrzuca H_0 w około 95.3% przypadków, a dla pozostałych modeli (BL, trend, sezon) częstość ta wynosi 1. Testy formalne również wykazują bardzo wysoką moc: wartości odrzucenia dla testu Boxa-Pierce'a mieszczą się między 0.55 a 1, a w teście Ljunga-Boxa osiągają nawet 0.69 - 1.

Oznacza to, że wszystkie trzy testy: graficzny, Boxa-Pierce'a i Ljunga-Boxa, skutecznie identyfikują modele z autokorelacją, trendem lub sezonowością jako niezgodne z białym szumem.

2.3.5 Wpływ ilości powtórzeń na częstość odrzucenia H_0

Tabela 5: Wpływ liczby powtórzeń R na oszacowanie częstości odrzucenia H0 (BS_norm, n = 100, h.max = 25).

model	n	ile_powtorz	h.max	graf_odrz	bp_odrz	lb_odrz
BS_norm	100	100	25	0.180	0.030	0.060
BS_norm	100	500	25	0.228	0.028	0.080
BS_norm	100	1000	25	0.222	0.027	0.084

Wnioski:

Zmiana liczby powtórzeń R wpływa jedynie na niewielkie wahania estymowanych częstości odrzucenia hipotezy H_0, co widać w tabeli 5. Dla $R = 100$ częstość odrzucenia testu graficznego wynosi 0.18, natomiast dla $R = 500$ spada do 0.228, co jest zgodne z tym, że mniejsza liczba powtórzeń daje bardziej rozrzutne oszacowania. Testy formalne pozostają stabilniejsze: dla Boxa-Pierce'a wartości zmieniają się od 0.03 do 0.027, a dla Ljunga-Boxa od 0.06 do 0.084. Wskazuje to, że wpływ liczby powtórzeń na wyniki testów jest niewielki, a większe R jedynie redukuje wariancję estymacji, nie zmieniając ogólnych wniosków dotyczących zachowania testów.

2.3.6 Podsumowanie

Przeprowadzone symulacje pokazują wyraźne różnice między testem graficznym a testami formalnymi w ocenie białoszumowości. Test graficzny okazał się najbardziej wrażliwy na długość szeregu oraz wybór maksymalnego opóźnienia h_{max}; przy krótkich szeregach i dużym h_{max} często generował fałszywe odrzucenia hipotezy H_0. Testy formalne Boxa-Pierce'a i Ljunga-Boxa charakteryzowały się znacznie większą stabilnością - dla białego szumu utrzymywały poziom odrzucenia bliski poziomowi istotności, niezależnie od parametrów symulacji. Jednocześnie obydwa testy wykazały bardzo wysoką moc w przypadku procesów niebędących białym szumem (MA(1), błądzenie losowe, trend, sezonowość), gdzie niemal zawsze poprawnie odrzucały H_0. Wyniki te wskazują, że test graficzny jest użytecznym narzędziem wstępnej diagnostyki, jednak przy analizie danych o małej długości lub przy dużej liczbie opóźnień może być zawodny. Testy formalne są bardziej wiarygodne i powinny stanowić podstawową metodę weryfikacji białoszumowości.

3 Zadanie 4

Cel zadania: Zastosowanie i porównanie wybranych metod dekompozycji, w kontekście ich zastosowania do eliminacji trendu i sezonowości.

Do wykonania zadania wybieramy szereg czasowy *pkb* z pakietu *TSAFBook*.

3.1 Analiza podstawowych danych szeregu

Sprawdźmy podstawowe własności wybranych danych (liczbę danych, okres czasu, częstotliwość).

Tabela 6: Podstawowe właściwości szeregu czasowego pkb

Właściwość	Wartość
Liczba obserwacji	78
Częstotliwość	4
Początek	1995 Q1
Koniec	2014 Q2

Tabela 6 pokazuje, że szereg składa się z 78 obserwacji. Częstotliwość danych wynosi 4, co odpowiada danym kwartalnym. Początek szeregu przypada na pierwszy kwartał 1995 roku, natomiast ostatnia dostępna obserwacja obejmuje drugi kwartał 2014 roku.

Zwizualizujmy kształt wykresu oraz określmy graficznie występowanie charakterystycznych własności (potencjalnych trendów, sezonowości, nie/jednorodności wariancji oraz występowania wartości odstających).

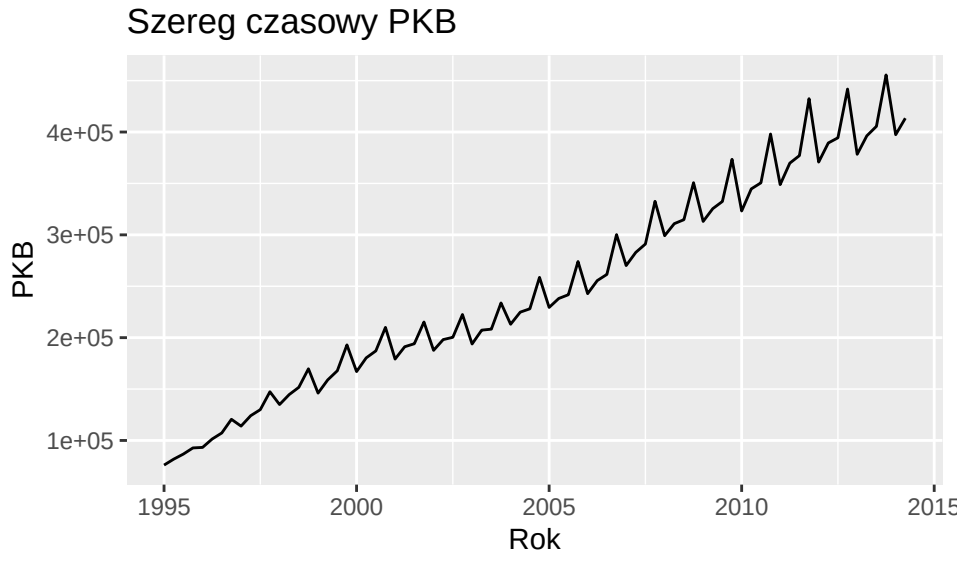

Rysunek 5: Wykres szeregu czasowego pkb

Na podstawie rysunku 5 możemy zasugerować występowanie trendu rosnącego oraz występowanie pewnej sezonowości, a także delikatnie zwiększającą się z czasem wariancję. Zweryfikujmy te obserwacje i przyjrzyjmy się dokładniej tym własnościom.

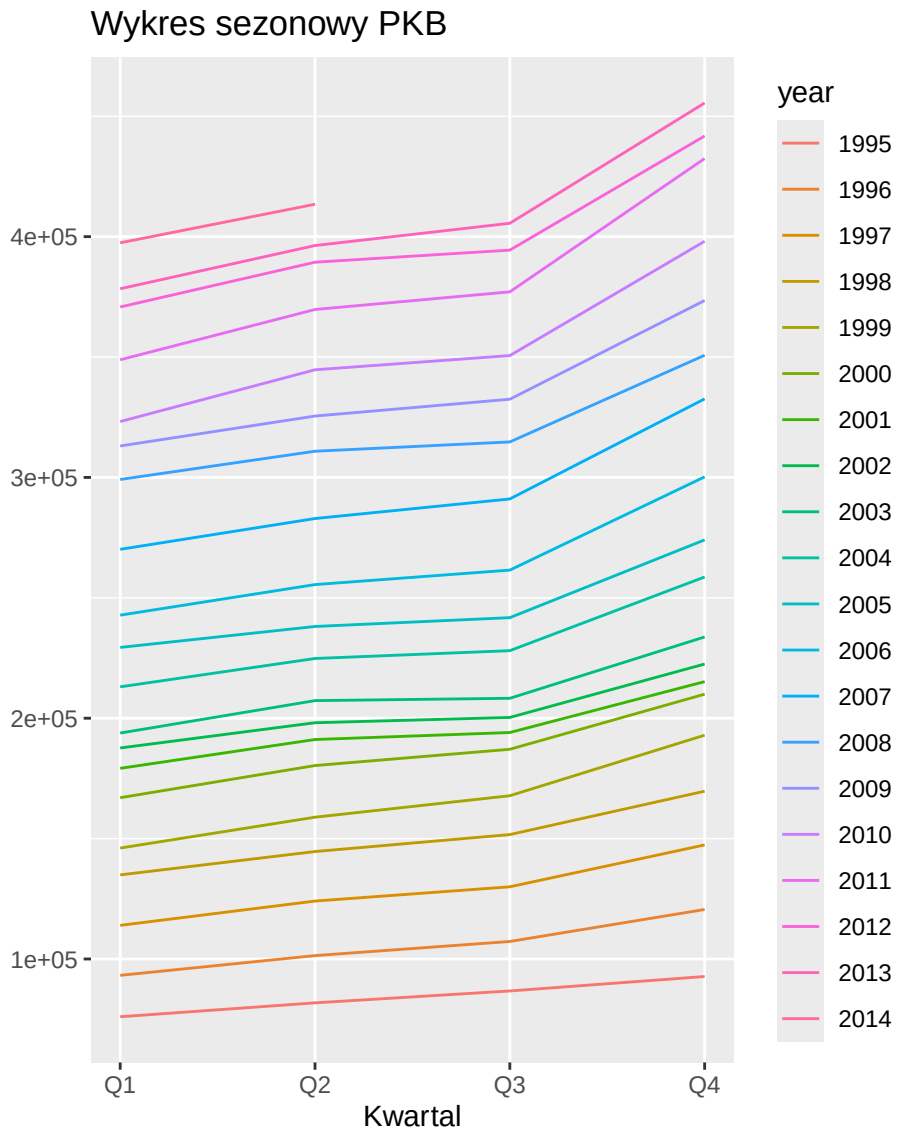

Rysunek 6: Wykres sezonowości szeregu czasowego pkb

Na rysunku 6 jasno i wyraźnie widać dwa główne zjawiska:

1. Trend rosnący - linie odpowiadające kolejnym latom są coraz wyżej, co wskazuje na systematyczny wzrost PKB.
2. Sezonowść kwartalna - w każdym roku możemy dostrzec pewien wzorzec: najniższe wartości przypadają na początek roku ($Q1$), delikatny wzrost w drugim kwartale ($Q2$), stabilizacja lub minimalne wzrosty/spadki w trzecim kwartale ($Q3$) oraz zdecydowanie najwyższe wartości na koniec roku ($Q4$).

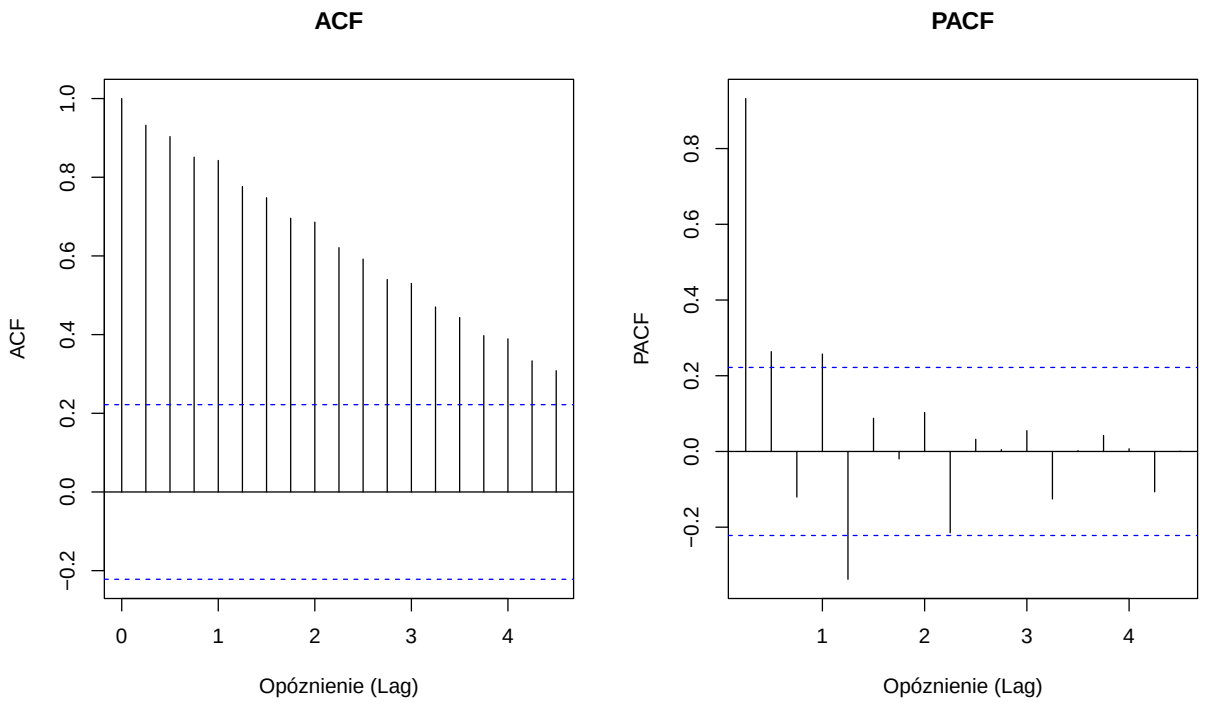

Rysunek 7: Wykres funkcji autokorelacji i funkcji częściowej autokorelacji szeregu czasowego pkb

Rysunek 7 przedstawia wykresy funkcji autokorelacji (ACF - lewy wykres) oraz funkcji częściowej autokorelacji (PACF - prawy wykres). Wykres autokorelacji wykazuje stały, wolny spadek autokorelacji z wartościami znajdującymi się znacznie ponad górną granicą przedziału ufności. Wskazuje to na silną zależność między kolejnymi obserwacjami (obecność pewnej sezonowości) oraz na występowanie pewnej (silnej) deterministycznej składowej trendu. Jest to fundamentalna oznaka niestacjonarności szeregu.

Zatem z wykresów widzocznych na rysunku 6 oraz rysunku 7 możemy stwierdzić, że szereg czasowy *pkb* jest szeregiem niestacjonarnym i charakteryzuje się pewnym powtarzalnym wzorcem sezonowym oraz trendem rosnącym, co właściwie sugerował nam wykres 5.

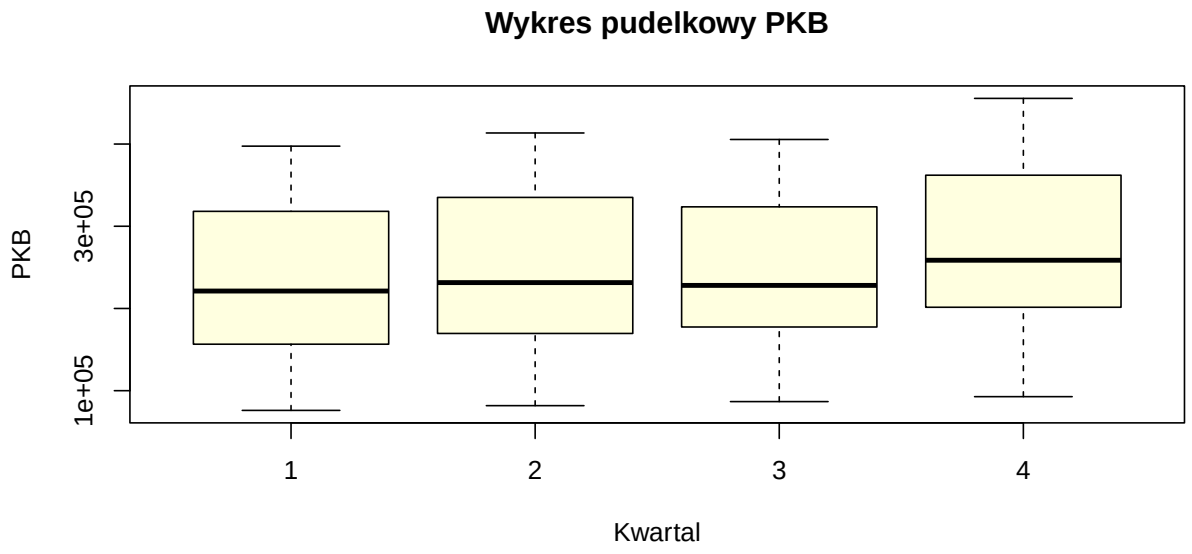

Rysunek 8: Wykres pudełkowy szeregu czasowego pkb

Na podstawie wykresu widocznego na rysunku 8 możemy stwierdzić, że nie mamy do czynienia z żadnymi znaczącymi wartościami odstającymi. Potwierdza on również istnienie silnej i powtarzalnej sezonowości kwartalnej. Poziomy mediany oraz rozrzuty danych są bardzo do siebie podobne. Delikatnie widoczne są zależności wcześniej wspomniane - okres szczytowy zawsze przypada na ostatni kwartał $Q4$.

3.2 Porównanie wyników dla poznanych metod dekompozycji szeregu czasowego

W tej części zastosujemy trzy metody dekompozycji szeregu czasowego:

1. dekompozycja na podstawie ruchomej średniej
2. dekompozycja na podstawie modelu regresji
3. dekompozycja STL oparta na metodzie loess

Porównamy je między sobą oraz stwierdzimy, ocenimy jakość ich dopasowania.

3.2.1 Dekompozycja na podstawie ruchomej średniej

Zacznijmy od dekompozycji na podstawie ruchomej średniej wyszczególniając przypadek dekompozycji addytywnej oraz multiplikatywnej.

Dekompozycja addytywna

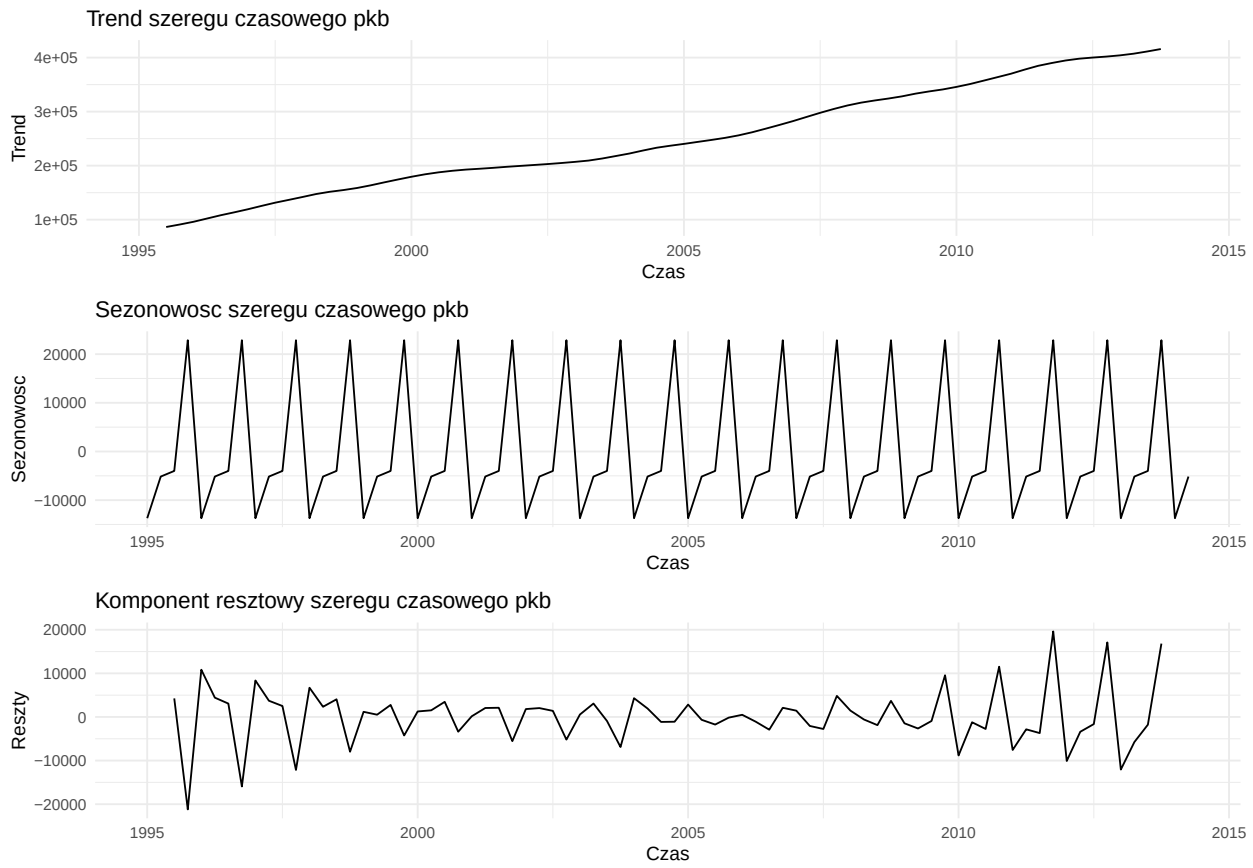

Rysunek 9: Dekompozycja addytywna szeregu PKB: trend, sezonowość i reszty.

Dekompozycja addytywna widoczna na rysunku 9 przedstawia trzy niezależne komponenty szeregu czasowego: trend, sezonowość oraz resztę.

Komponent trendu

Wyraźna długoterminowa rosnąca krzywa, reprezentująca stały wzrost gospodarczy, potwierdza wcześniejszy wniosek o niestacjonarności szeregu (widoczny trend).

Komponent sezonowości

Bardzo silne, regularne, powtarzające się cykle (zbliżone do sinusoidalnej) o okresie 4 obserwacji (wskazanie na dane kwartalne). Wzór powtarza się praktycznie idealnie co rok - amplituda wahań jest stała.

Komponent reszty

Reprezentuje to, co pozostało po odjęciu trendu i sezonowości. Wartości reszt w środkowej części szeregu fluktuują wokół zera, lecz na początku i na końcu próby widać kilka znaczących odchyleń. Dostrzegamy również niejednorodność wariancji, sugerując brak stacjonarności, lecz przyjrzyjmy się jeszcze wykresom ACF oraz PACF.

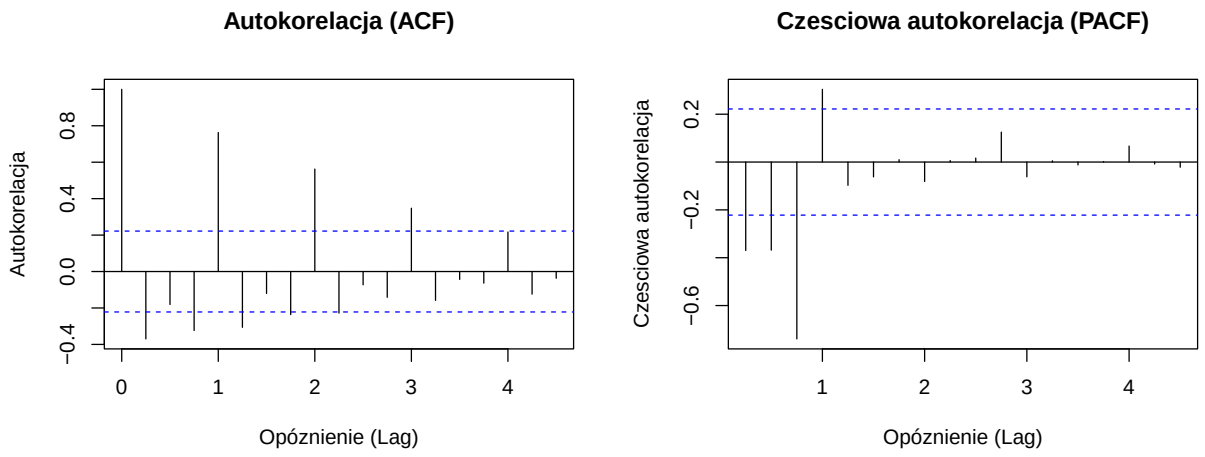

Rysunek 10: Komponent resztowy szeregu PKB oraz jego ACF i PACF (dekompozycja addytywna)

Analizując wykresy ACF i PACF (rys. 10) dostrzegamy, że wykres ACF wykazuje wartości znacząco przewyższające górną granicę przedziału ufności na pierwszych kilku opóźnieniach oraz ślady sezonowości. Zatem możemy stwierdzić, że dekompozycja addytywna nie wyeliminowała całej struktury zależności szeregu (nie ma stacjonarności).

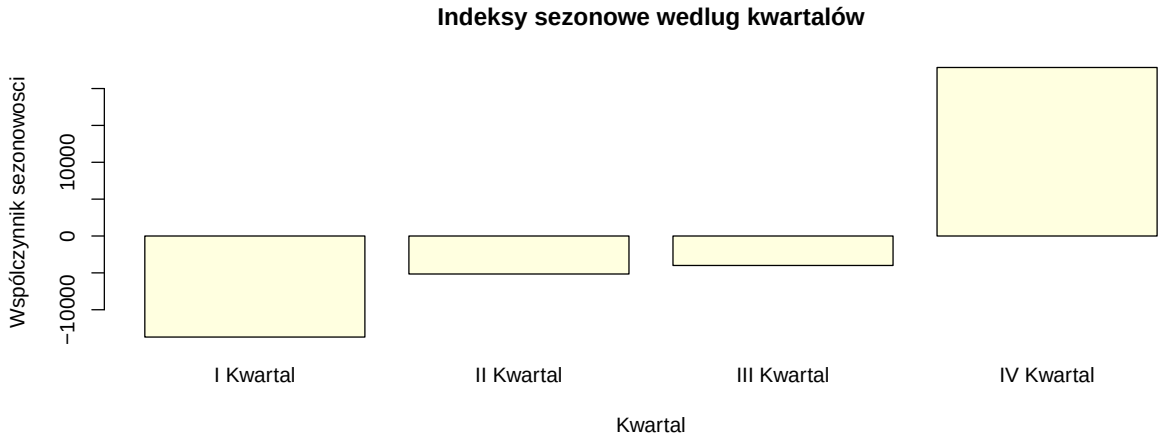

Rysunek 11: Wykres pudełkowy indeksów sezonowości dla dekompozycji addytywnej

Rysunek 11 ukazuje, że w badanym szeregu wartości PKB występuje silna i powtarzalna dysproporcja w aktywności gospodarczej w ciągu roku (znacząca asymetria sezonowa), z kumulacją produkcji i konsumpcji w IV kwartale.

Dekompozycja multiplikatywna

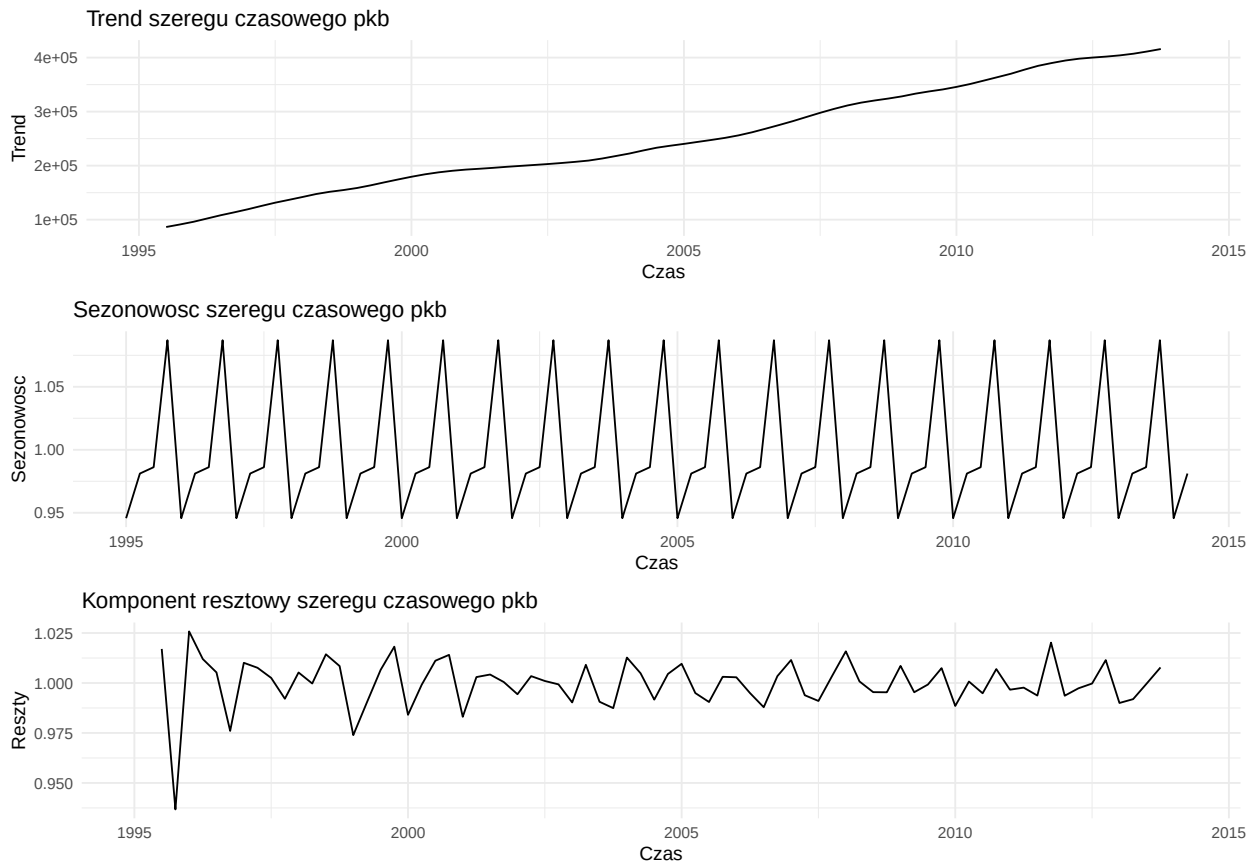

Rysunek 12: Dekompozycja multiplikatywna szeregu czasowego pkb: trend, sezonowość i reszty

Dekompozycja multiplikatywna widoczna na rysunku 12 tak jak addytywna przedstawia trzy niezależne komponenty szeregu czasowego: trend, sezonowość oraz resztę.

Komponent trendu i komponent sezonowości

Wnioski takie same jak dla dekompozycji addytywnej.

Komponent reszty

Wartości reszt w tym przypadku fluktuują wokół 1.0, z jednym większym odchyleniem na początku szeregu. Przyjrzyjmy się wykresom ACF oraz PACF.

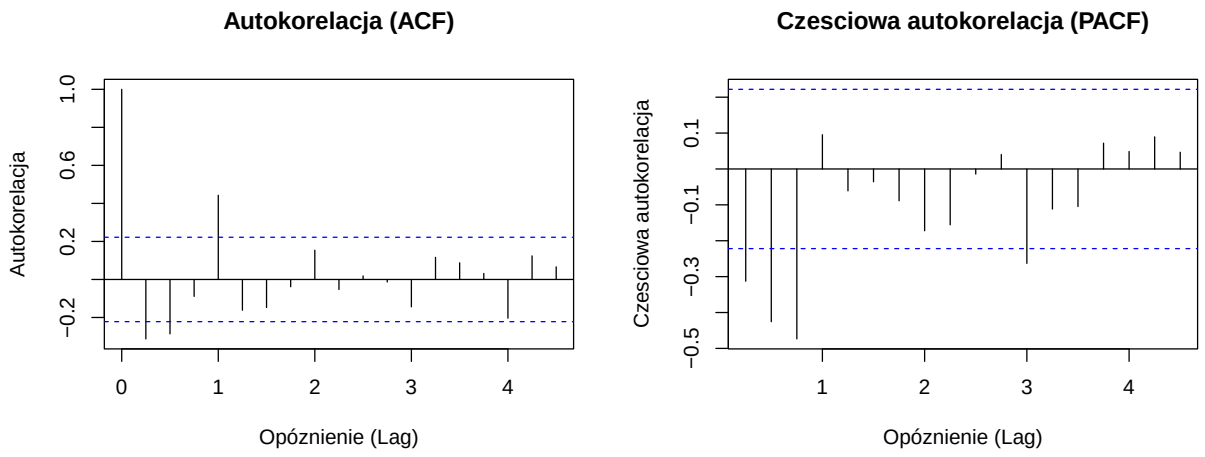

Rysunek 13: Komponent resztowy szeregu PKB oraz jego ACF i PACF dla dekompozycji multiplikatywnej.

Na wykresie ACF i PACF (rysunek 13) dostrzegamy wartości wykraczające poza granice przedziału ufności. Na wykresie reszty zauważalne są także potencjalne pozostałości po sezonowości, sugerujące brak charakteru stacjonarnego. Mimo to, możemy stwierdzić, że modelowi dekompozycji multiplikatywnej jest nieco bliżej charakteru stacjonarnego, niż to miało miejsce w przypadku dekompozycji addytywnej.

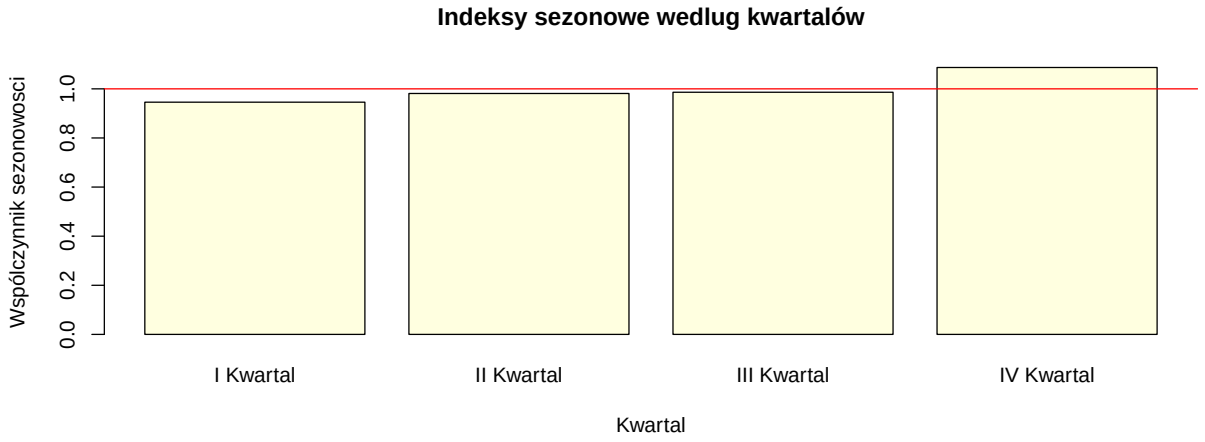

Rysunek 14: Wykres pudełkowy indeksów sezonowości dla dekompozycji multiplikatywnej

Podobnie jak w modelu addytywnym, IV kwartał jest kwartałem dominującym, z najwyższym wskaźnikiem (ponad 1.0). W pozostałych kwartałach PKB jest bliskie trendowi (nieco niższe), co wydaje się być bliższe rzeczywistości niż to co sugerował model addytywny (który dawał duże wartości ujemne dla $Q1$).

Wnioski

Po przeanalizowaniu obu modeli dekompozycji, możemy stwierdzić, że analiza dekompozycji multiplikatywnej prowadzi do lepszych wyników diagnostycznych niż dekompozycja addytywna i jest ona bardziej adekwatna dla analizowanego szeregu czasowego pkb.

3.2.2 Dekompozycja na podstawie modelu regresji

W przypadku dekompozycji na podstawie modelu regresji rozpatrzymy następujące modele:

1. regresja względem trendu liniowego,
2. regresja względem trendu liniowego z sezonowością,
3. regresja względem trendu kwadratowego oraz sezonowością,
4. regresja względem trendu postaci wielomianu trzeciego stopnia z sezonowością.

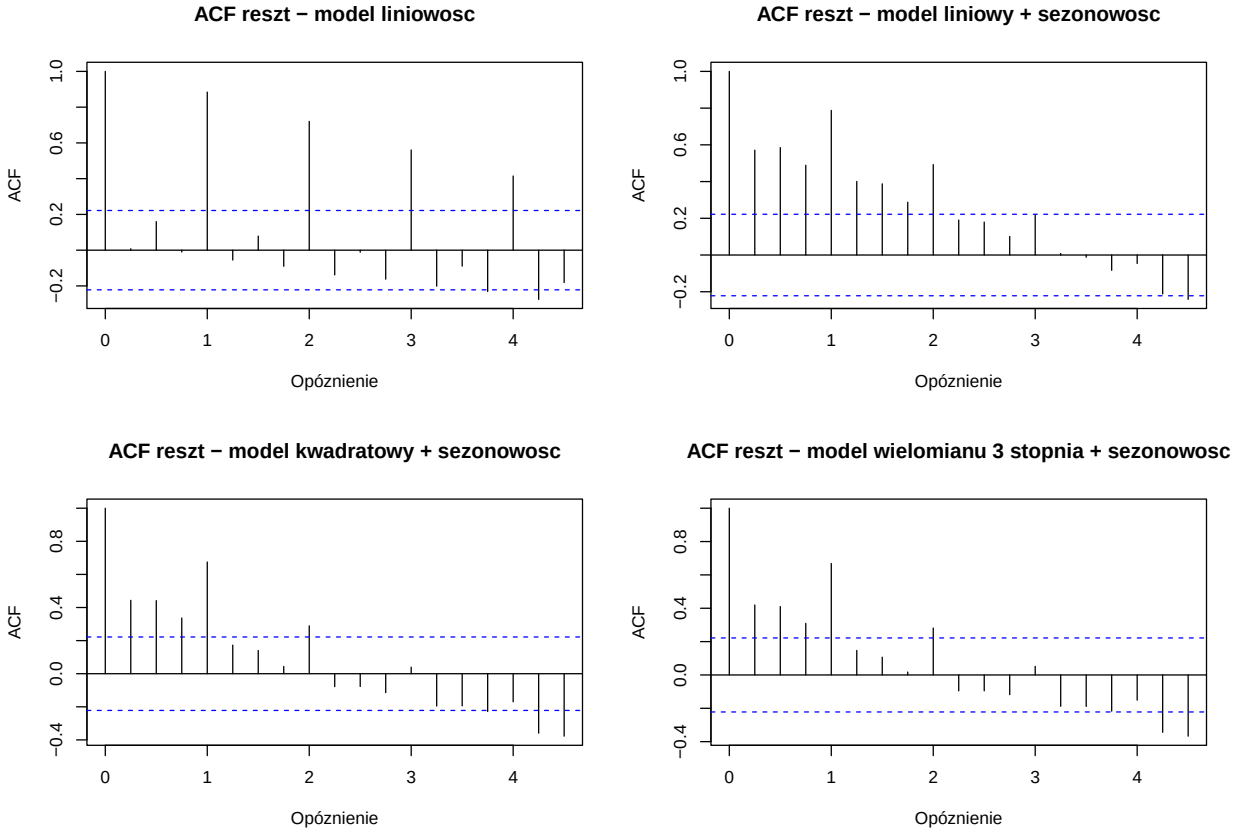

Rysunek 15: Wykres funkcji autokorelacji oraz wartości reszt dla różnych modeli regresji

Tabela 7: Wartości wskaźnika dopasowania modelu

Model	Skorygowane R^2
Trend liniowy	0.9677896

Model	Skorygowane R^2
Trend liniowy + Sezonowość	0.9854643
Trend kwadratowy + Sezonowość	0.9885423
Trend wielomianowy 3. st. + Sezonowość	0.9886750

Porównując wskaźnik dopasowania (tabela 7) oraz analizy reszt (wykresy na rysunku 15), możemy stwierdzić, że modele z trendem liniowym są nieodpowiednie, ponieważ na wykresach ACF ich reszt widać dużą ilość wartości znacząco wychodzących poza granice przedziału ufności, co oznacza występowanie potencjalnych niewychwyconych zależności.

Z kolei modelom o trendzie kwadratowym i trendzie postaci wielomianu 3. stopnia jest zdecydowanie bliżej osiągnięcia stacjonarności. Różnica w dopasowaniu (R^2) między tymi dwoma modelami jest jednak marginalna. Zatem regresję z trendem kwadratowym z sezonowością możemy uznać za wystarczającą i optymalną.

3.2.3 Dekompozycja STL oparta na metodzie loess

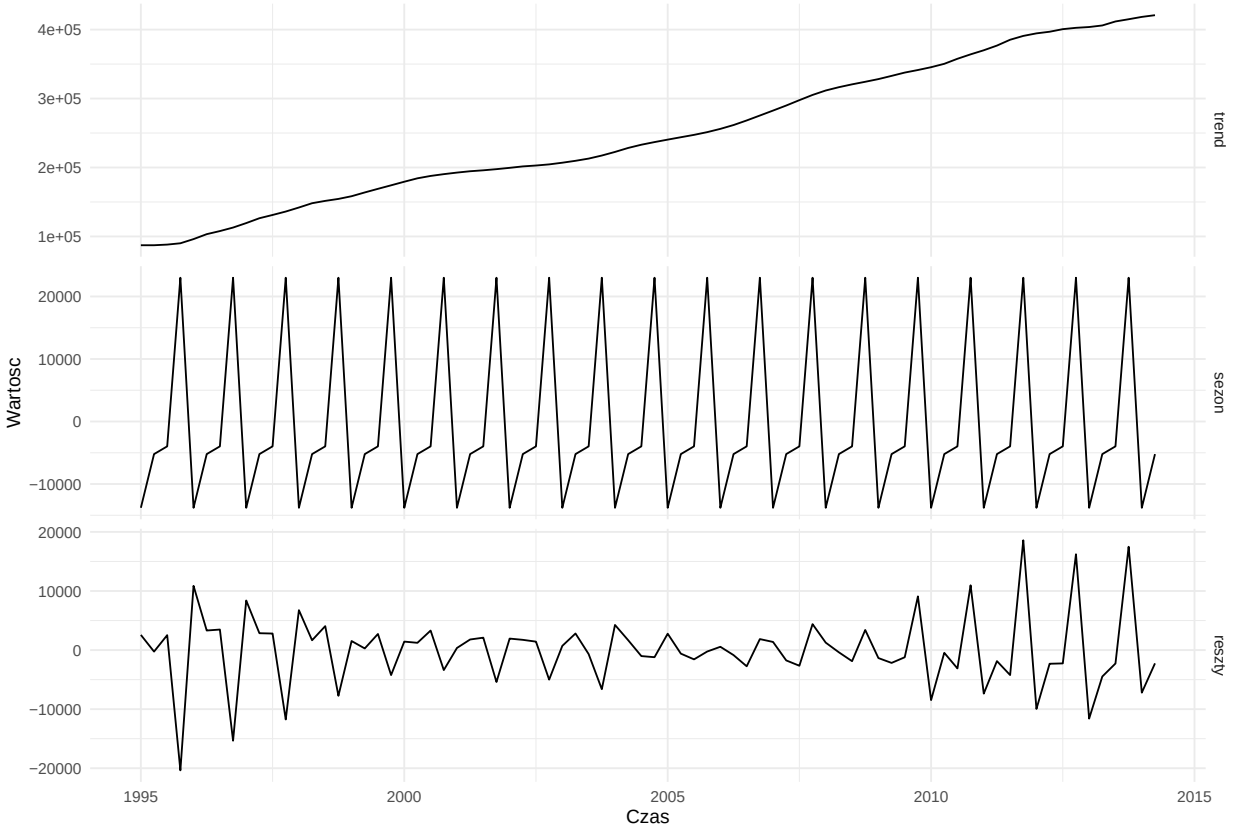

Rysunek 16: Wykres dekompozycji SLT szeregu czasowego pkb

Wykres dekompozycji STL (rysunek 16) potwierdza, że trend jest rosnący, a sezonowość wykazuje cykliczne wahania kwartalne. Analiza komponentu resztowego wskazuje na pewną niejednorodność wariancji szeregu (zmienność większa na krańcach szeregu). Podobnie jak w przypadku klasycznej dekompozycji addytywnej, ta diagnoza sugeruje, że czysty model addytywny może nie być optymalnym wyborem dla badanego szeregu, i że lepszym rozwiązaniem prognostycznym jest model regresji z nieliniowym trendem.

3.3 Weryfikacja dopasowania poszczególnych modeli

W poprzedniej sekcji stosowaliśmy 3 metody dekompozycji i na ich podstawie wyciągaliśmy informacje o stacjonarności oraz niestacjonarności szeregu (wystepowaniu trendów, sezonowości itp.). Próbowaliśmy również ocenić, który model najlepiej poradzi sobie z estymacją wartości badanego szeregu czasowego. Zweryfikujmy je.

3.3.1 Dekompozycja na podstawie ruchomej średniej

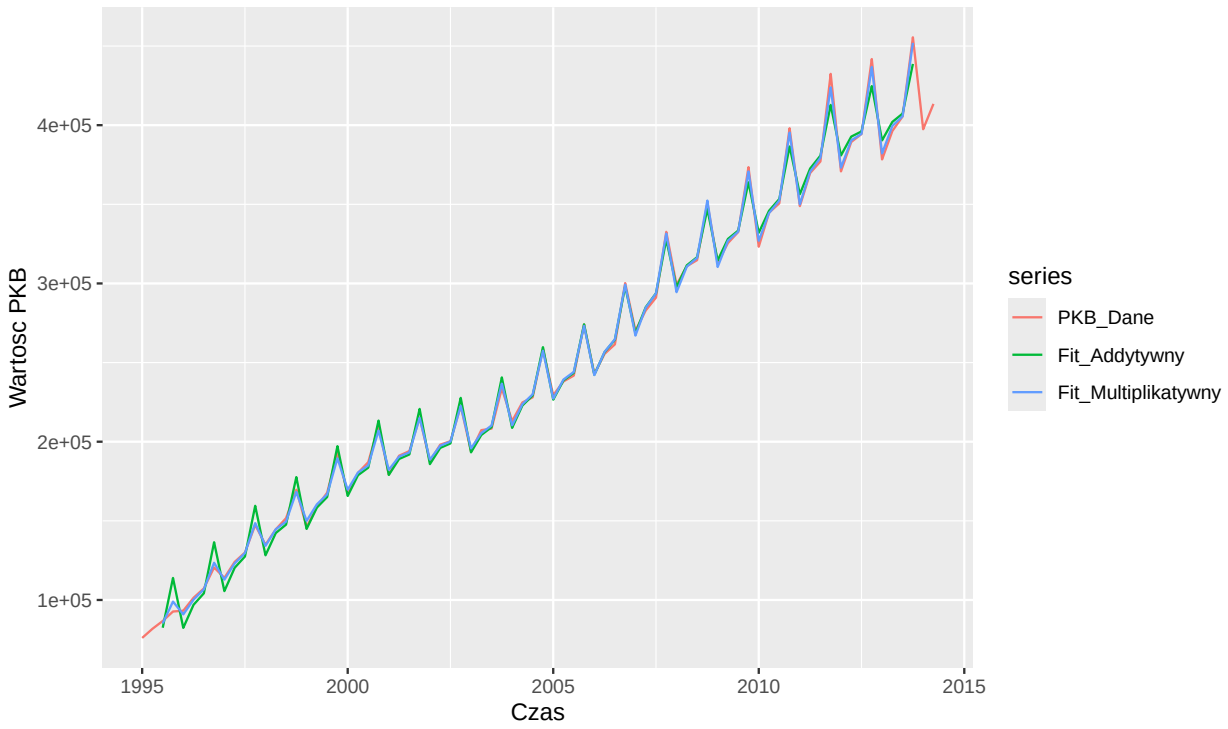

Rysunek 17: Wykres dopasowania dekompozycji na podstawie średniej ruchomej

Jak widać na rysunku 17, mimo niewielkich różnic w środkowej części szeregu, na początku jak i na końcu szeregu znacznie lepiej dopasowanym modelem (będącym bliżej danych) do analizowanego szeregu jest dekompozycja multiplikatywna. Udaje jej sie, w przeciwieństwie do modelu addytywnego, wychwycić multiplikatywność sezonowości.

3.3.2 Dekompozycja na podstawie modelu regresji

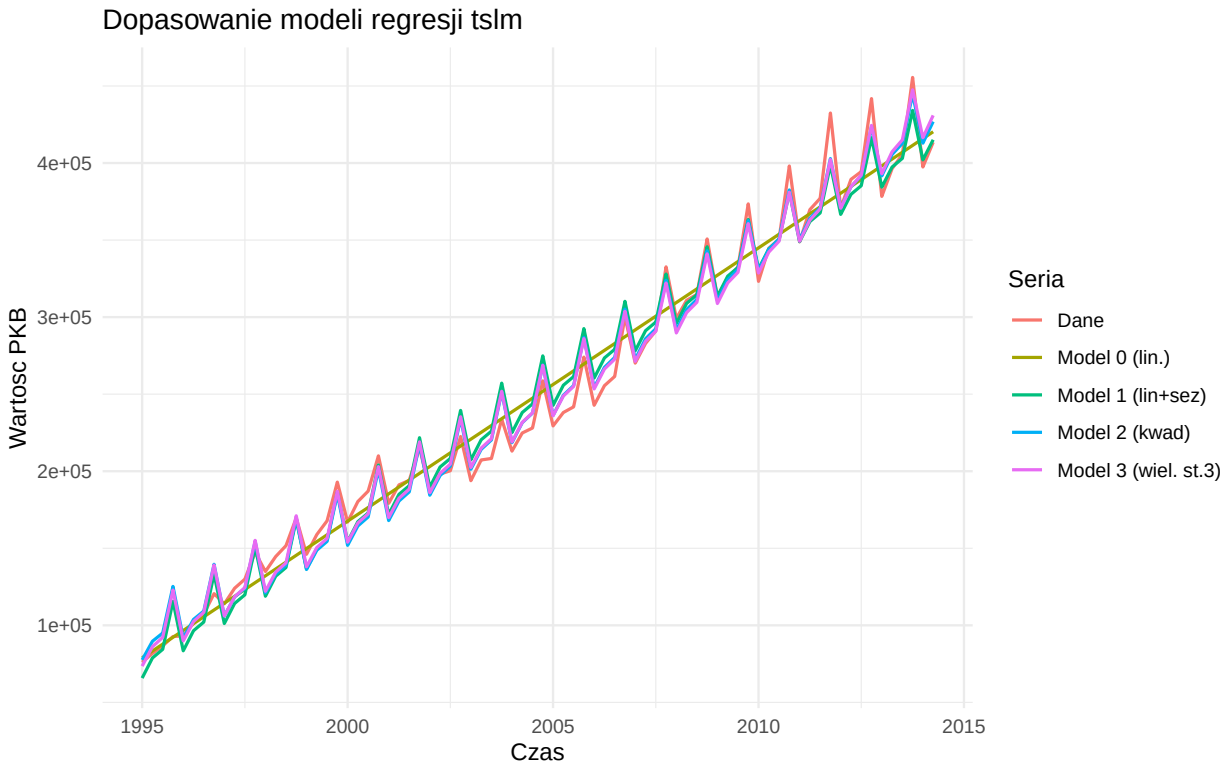

Rysunek 18: Wykres metody regresji dla dekompocycji szeregu czasowego pkb

Tak jak założyliśmy i uzasadniliśmy w poprzedniej sekcji - najlepiej odwzorowującym i optymalnym modelem jest model regresji kwadratowej z sezonowością. Na rysunku \ref{regresjatest) widzimi, że modele liniowe bardzo niedokładnie estymują badane dane, nie oddając prawidłowo sezonowości ani regularności. Wizualnie nie widać szczególnej różnicy między trendem kwadratowym jak i trendem postaci wielomianu trzeciego stopnia, co również potwierdza prawdziwość naszej wcześniejszej analizy.

3.3.3 Dekompozycja STL oparta na metodzie loess

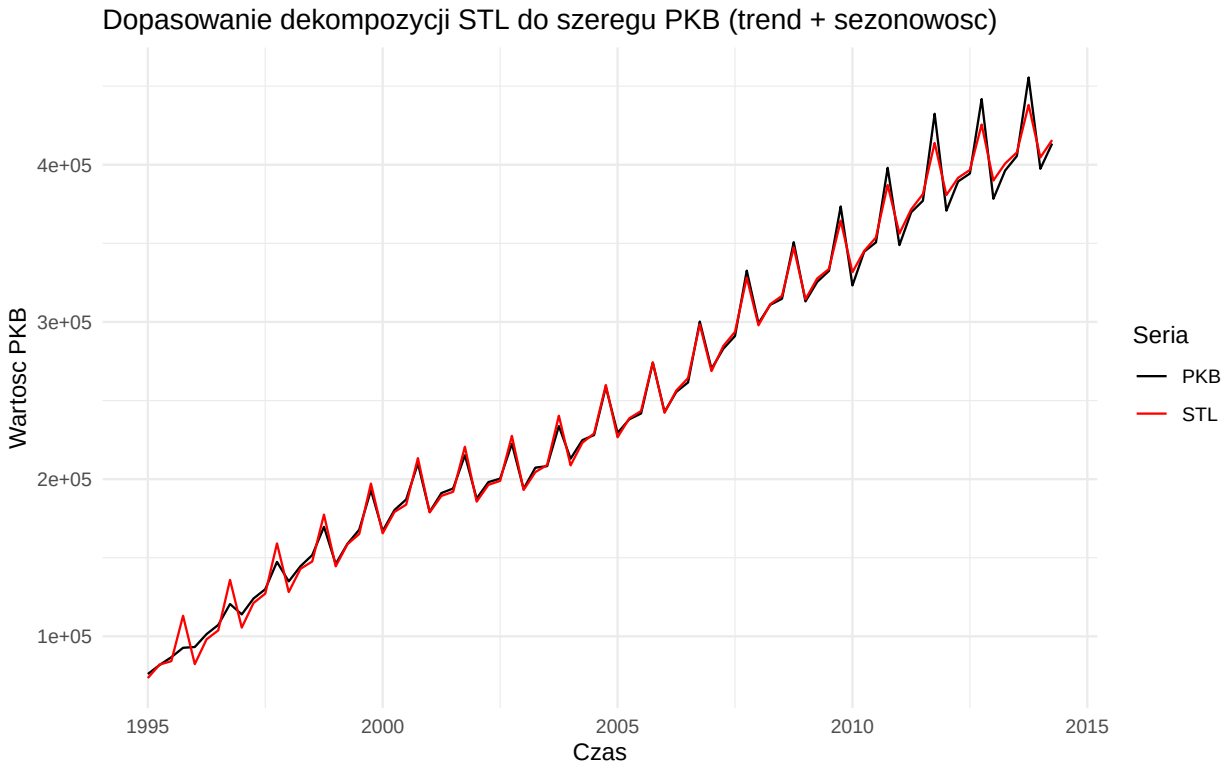

Rysunek 19: Wykres porównawczy dekompozycji stl dla dekompocycji szeregu czasowego pkb

Jak widać na rysunku 19 dopasowanie do wykresu oryginalnych danych jest bardzo podobne jak to w przypadku klasycznej dekompozycji addytywnej - niedokładne dopasowanie, szczególnie na krańcach wykresu.

3.3.4 Porównanie najlepszych dopasowań

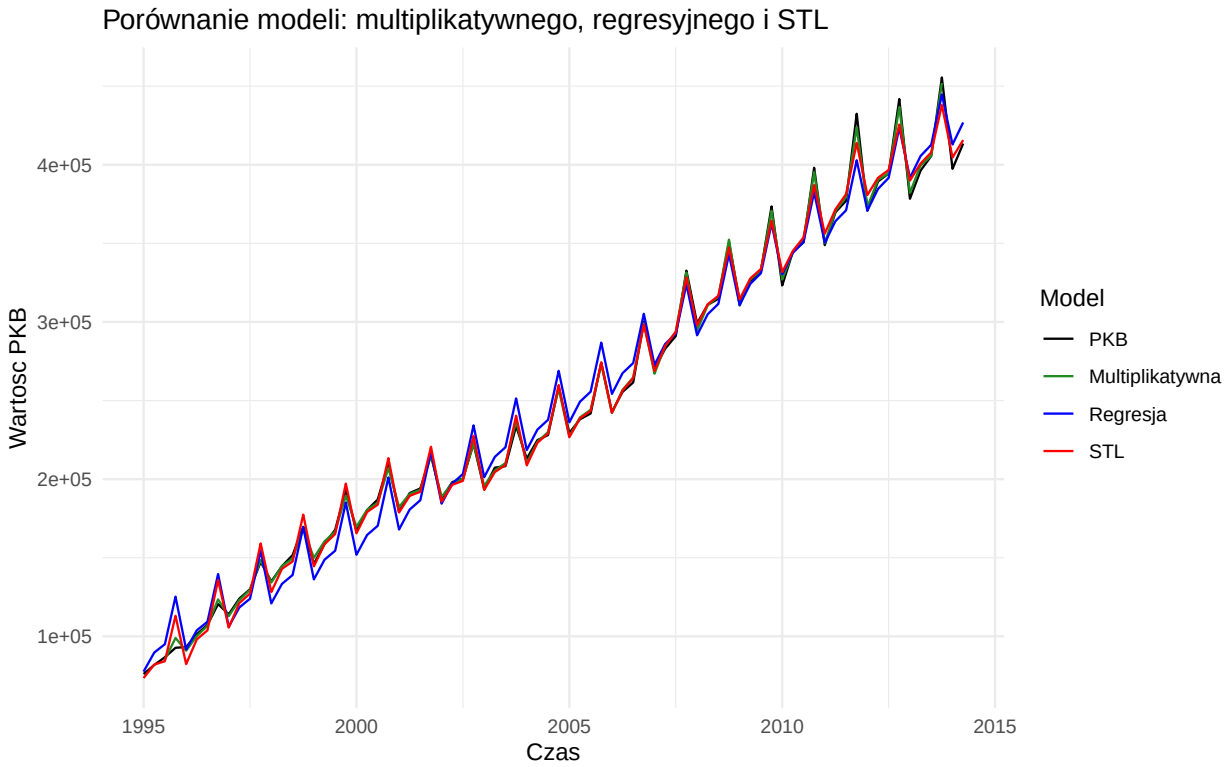

Rysunek 20: Wykres porównawczy dekompozycji najlepiej pasujących do szeregu czasowego pkb

Na podstawie rysunku 20 możemy stwierdzić że najlepsze dopasowanie do oryginalnych danych badanego szeregu reprezentuje dekompozycja oparta na podstawie ruchomej średniej - dekompozycja multiplikatywna, która zapewnia najbliższe przybliżenie (względem oryginalnych danych), szczególnie na krańcach szeregu czasowego.

3.4 Wpływ wyboru parametrów na wyniki danej metody dekompozycji

W poprzednich sekcjach analizowaliśmy jakość dopasowania zarówno klasycznych dekompozycji (addytywnej i multiplikatywnej), jak i regresji szeregów czasowych, koncentrując się na wyborze odpowiedniego typu modelu i stopnia wielomianu trendu. Skoncentrujemy się teraz na metodzie STL, która, będąca najbardziej elastyczną, staje się najbardziej wrażliwa na wartości parametrów.

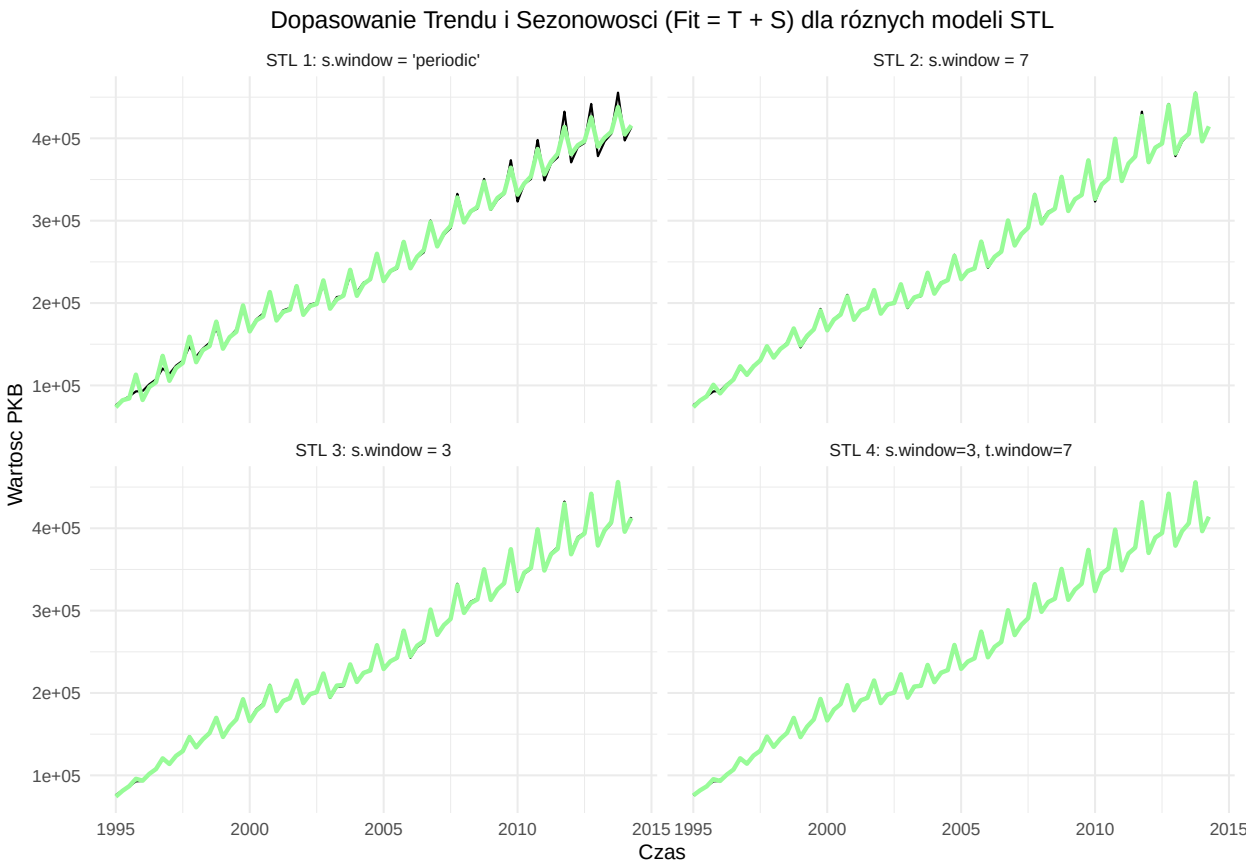

Rysunek 21: Porównanie dopasowania modeli STL (Fit = Trend + Sezonowość) do oryginalnego szeregu PKB dla różnych parametrów wygładzających.

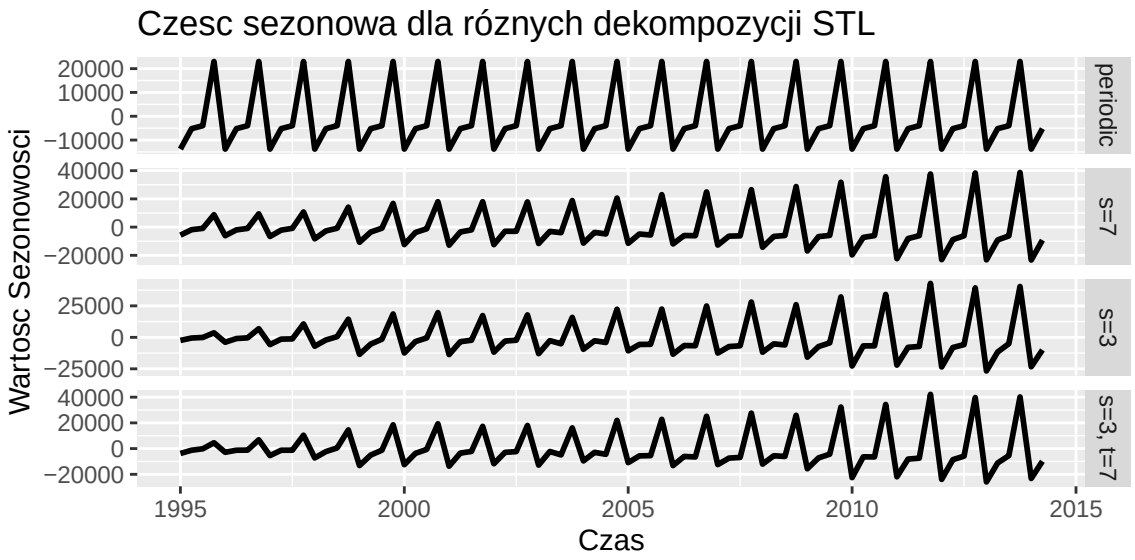

Rysunek 22: Porównanie komponentu sezonowego dla różnych parametrów STL (s.window i t.window).

Jak ukazują wykresy na rysunku 21 i rysunku 22 dobór parametrów może być kluczowy przy metodzie STL przy analizach szeregów czasowych.

Wariant STL z parametrem $s.window =$ "*periodic*" prowadzi do najbardziej sztywnego i najmniej zbliżonego dopasowania wartości danych jak i sezonowości z analizowanych wariantów. Amplituda przy komponencie sezonowym, w tym wariancie jest stała co nie do końca jest zgodne z prawdą. Na wykresie (rysunek 21) widać również znaczące odchylenia szczególnie na krańcach szeregu.

Wariant STL z parametrem $s.window = 7$ daje lepsze dopasowanie niż wariant $s.window =$ "*periodic*", choć też nieidealne. Odchylenia na wykresie (rysunek 21) wizualnie są minimalne, jednakże przyglądając się części sezonowej, można dostrzec jej niedokładne odwzorowanie, chociażby brak wychwycenia nieregularności w odchyleniach amplitudy pomiędzy latami $2000 - 2005$.

Dwa ostatnie warianty STL z parametrem $s.window = 3$ oraz z parametrami $s.window = 3, t.window = 7$ wypadają zdecydowanie najlepiej. Trend jest w nich wyraźny, płynny oraz zachowana zostaje elastyczna struktura sezonowości (wizualnie praktycznie identyczna), z czym nie poradziły sobie poprzednie dwa warianty.

Ostatecznie jednak na podstawie wykresu (rysunek 21) należy stwierdzić, że najlepszym dopasowaniem jest wariant STL z dodatkowym parametrem $t.window = 7$, który przykrywa praktycznie całą czarną krzywą (opisującą dane oryginalne), a w wariancie STL z pojedynczym parametrem $s.window = 3$ są jednak widoczne pewne (bardzo delikatne) odchylenia (minimalne fragmenty czarnego wykresu na końcu szeregu).

3.5 Zastosowanie transformacji Boxa-Coxa do poprawy jakości dopasowania modeli dekompozycji

Dla każdej metody dekompozycji zostaną wykonane porównania z wykorzystaniem transformacji logarytmicznej odpowiadająca wartości $\lambda = 0$.

3.5.1 Transformacja Boxa-Coxa dla metody na podstawie ruchomej średniej

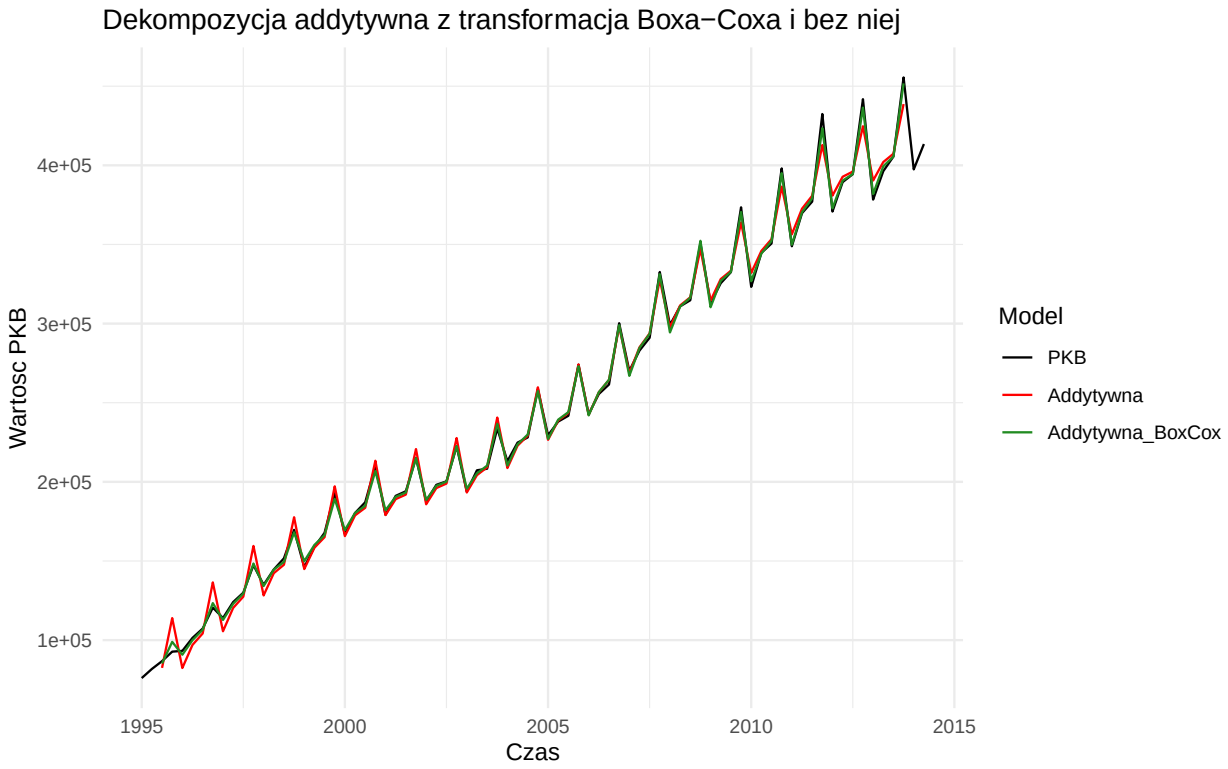

Rysunek 23: Wykres porównawczy dekompozycji addytywnej z i bez transformacji Boxa-Coxa

Wizualizacja wykresów widoczna na rysunku 23 wyraźnie wskazuje, że lepsze dopasowanie prezentuje metoda dekompozycji addytywnej z zastosowaniem transformacji Boxa-Coxa (lepsze dopasowanie na krańcach szeregu). Porównajmy ją zatem z dekompozycją multiplikatywną (ocenioną wcześniej przez nas jako lepszą).

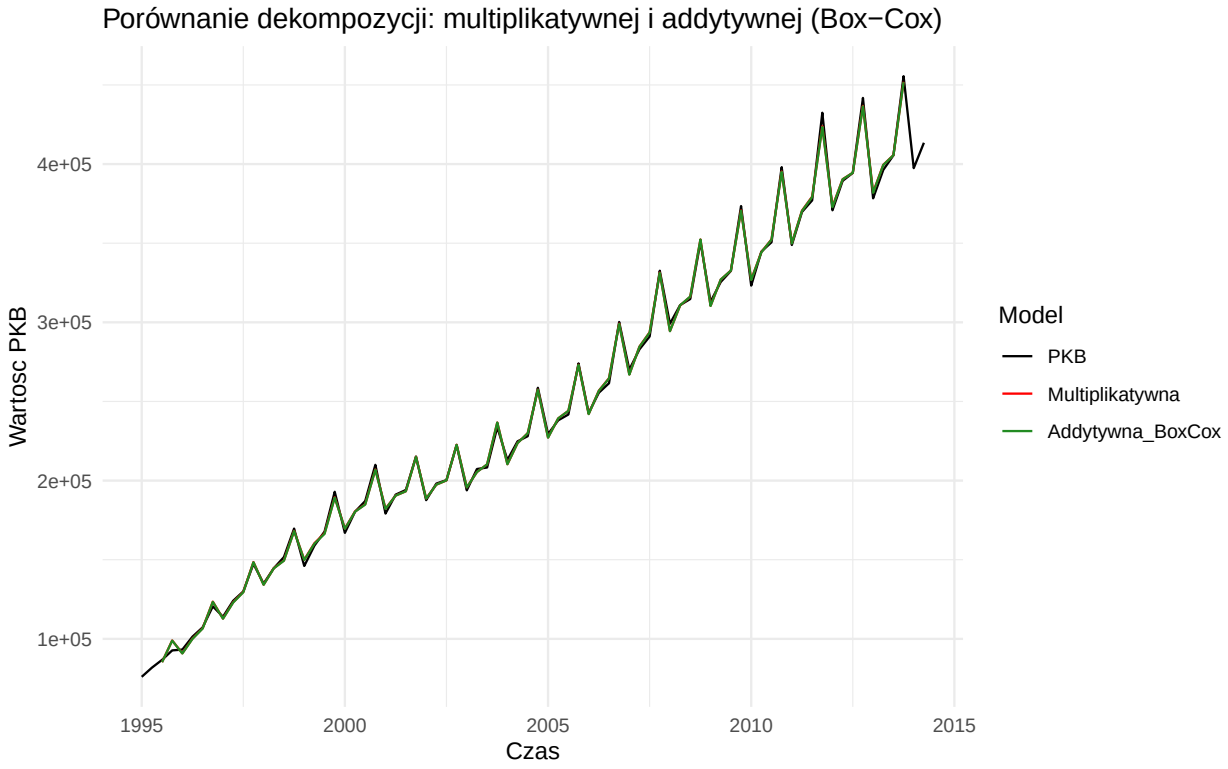

Rysunek 24: Wykres porównawczy dekompozycji multiplikatywnej i addytywnej z transformacją Boxa-Coxa

Na rysunku 24 nie dostrzegamy czerwonego wykresu (dekompozycja multiplikatywna), co oznacza, że przebiega ona praktycznie identycznie co dekompozycja addytywna z transformacją Boxa-Coxa. Obydwie linie idealnie pokrywają się z danymi, prawidłowo odwzorowując trend rosnący oraz sezonowość. Na podstawie tego, możemy wywnioskować, że zastosowanie transformacji Boxa-Coxa pozwala dekompozycji addytywnej uzyskać efekt zbliżony do modelu multiplikatywnego.

3.5.2 Transformacja Boxa-Coxa dla metody na podstawie modelu regresji

Tabela 8: Porównanie wartości wskaźnika dopasowania modelu (Skorygowane R^2) dla modelu regresji bez i z transformacją Boxa-Coxa

Model	Skorygowane R^2	Skorygowane R^2 (Box-Cox, $\lambda = 0$)
Trend liniowy	0.9677896	0.9438366
Trend liniowy + Sezonowość	0.9854643	0.9575215
Trend kwadratowy + Sezonowość	0.9885423	0.9827172
Trend wielomianowy 3. st. + Sezonowość	0.9886750	0.9893662

Tabela 8 ukazuje, że w przypadku dekompozycji na podstawie modelu regresji transformacja Boxa-Coxa nie poprawia dopasowania modelu do krzywej. Wartości skorygowanego R^2 są nieznacznie mniejsze (czyli gorsze) dla prawie wszystkich modelów regresji po zastosowaniu transformacji Boxa-Coxa (minimalnie lepiej wypada tylko trend postaci wielomianu 3 stopnia z sezonowością). Mimo to, wciąż współczynnik dopasowania dla funkcji kwadratowej po zastosowaniu transformacji Boxa-Coxa wynosi bardzo dużo - 0.9827, co powoduje, że jest on również wystarczającym, adekwatnym modelem.

3.5.3 Transformacja Boxa-Coxa dla metody STL

Zweryfikujmy wpływ metody Boxa-Coxa dla wersji, która wypadła najgorzej w sekcji 3.3.3, czyli dla wartosci parametru $s.window = "periodic"$.

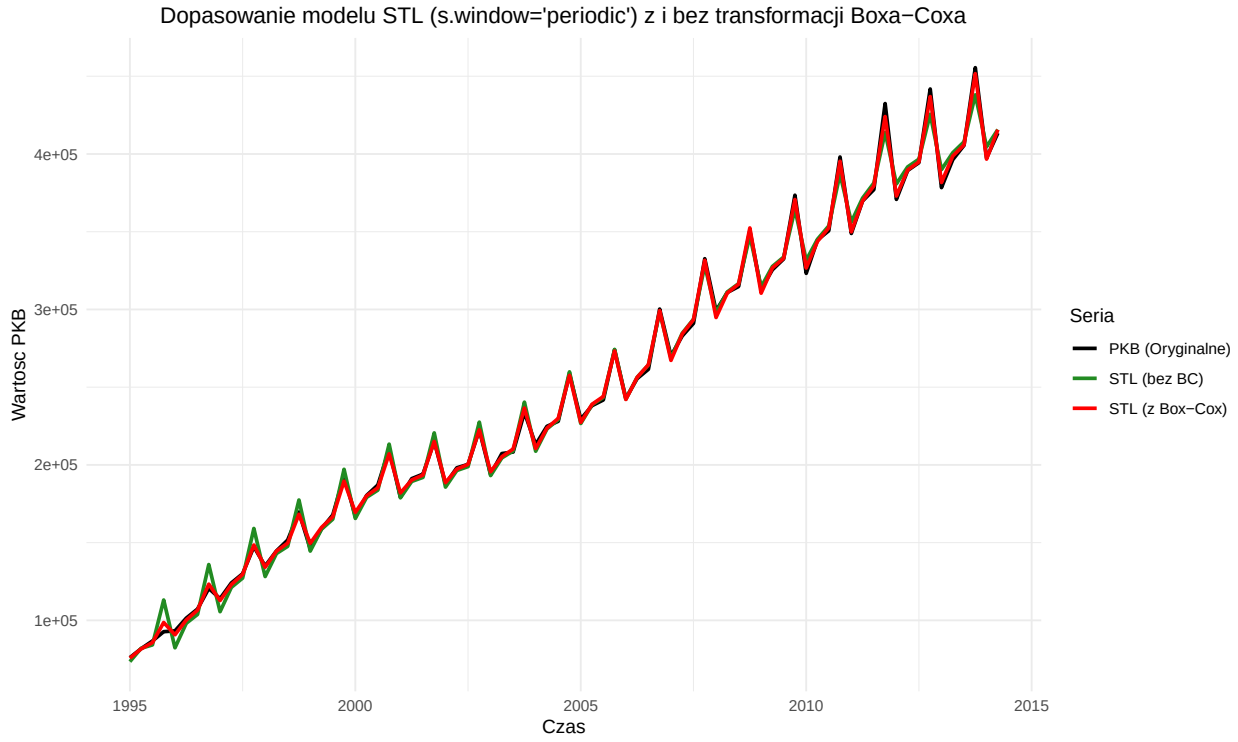

Rysunek 25: Porównanie dopasowania STL z i bez transformacji Boxa-Coxa

Na rysunku 25 można dostrzec minimalne różnice pomiędzy modelami, widoczne szczególnie na krańcach szeregu, gdzie transformowany model (STL z BC) wydaje się nieznacznie lepiej odwzorowywać wahania. Zatem, można powiedzieć, że Transformacja Boxa-Coxa z lambda=0 poprawiła dopasowanie w przypadku metody dekompozycji STL (w przeciwieństwie do dekompozycji opartej na metodzie regresji).

3.6 Porównanie metod eliminacji składowych (dekompozycja vs. różnicowanie danych

Rozpatrzymy głównie przypadki po zastosowaniu transformacji Boxa-Coxa.

3.6.1 Szereg po zróżnicowaniu

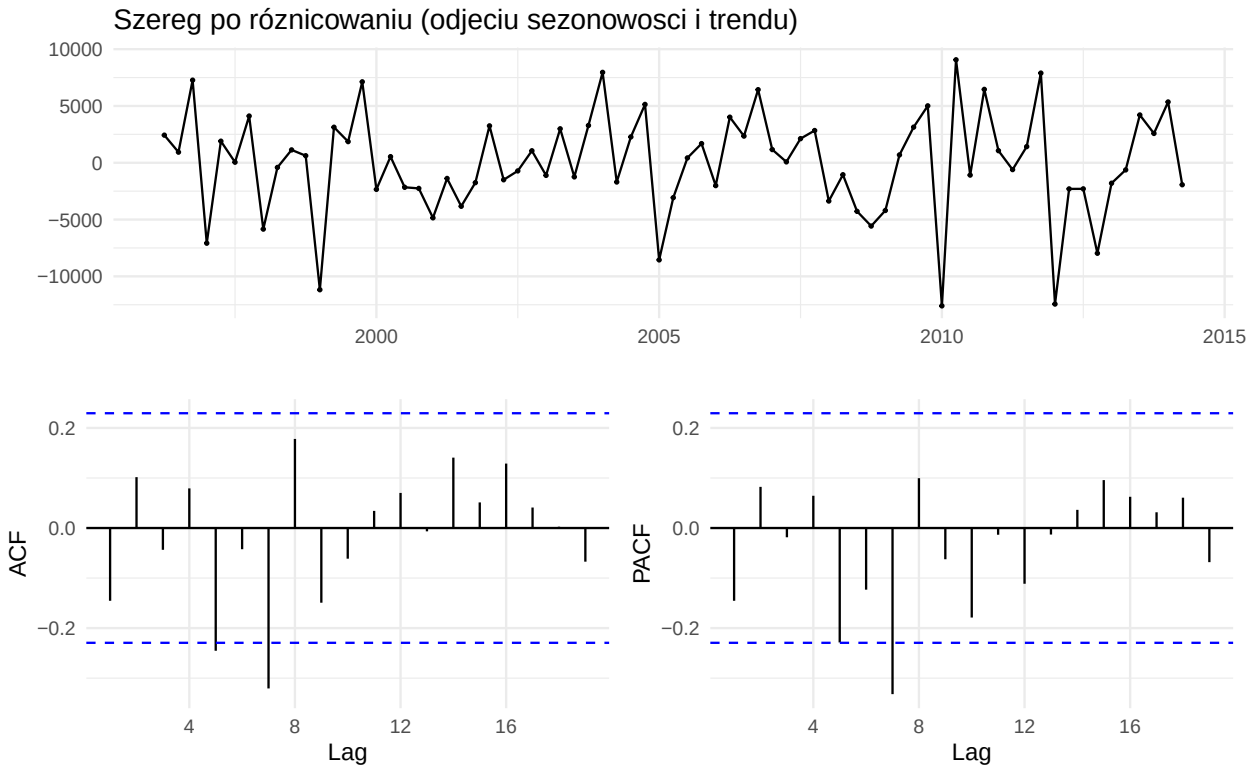

Rysunek 26: Wykresy szeregu pkb po zróżnicowaniu.

Po zastosowaniu podwójnego różnicowania z opóźnieniami 1 i 4 szereg PKB traci zarówno trend, jak i regularną sezonowość, które były bardzo wyraźnie widoczne w danych pierwotnych. Uzyskany szereg nie prezentuje już systematycznego wzrostu ani łatwo zauważalnych powtarzalnych kwartalnych wzorców, choć jego wartości pozostają zmienne i charakteryzują się dużą amplitudą. Wykresy funkcji ACF i PACF potwierdzają wygasanie autokorelacji i brak trwałych zależności czasowych. Wyróżnić możemy jednostkowe, delikatne przekroczenia granic przedziału ufności. Zatem na podstawie wykresów na rysunku 26 możemy stwierdzić, że otrzymany szereg po różnicowaniu można uznać za szereg o charakterze stacjonarnym.

3.6.2 Dekompozycja multiplikatywna

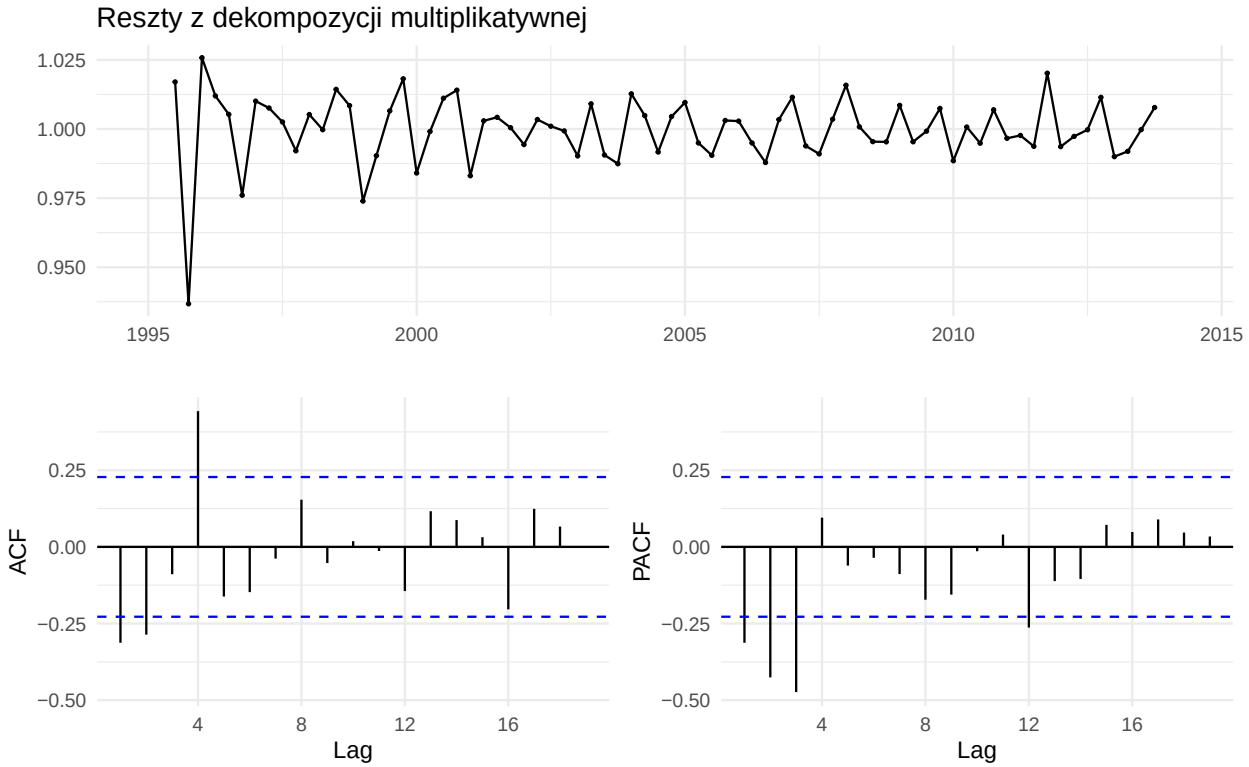

Rysunek 27: Diagnostyka reszt z dekompozycji multiplikatywnej.

Reszty uzyskane z dekompozycji multiplikatywnej są wyraźnie mniej zmienne od pierwotnego szeregu i oscylują wokół stałego poziomu. Mimo tego w szeregu widoczne są pewne regularne wahania oraz sporadyczne, większe odchylenia, które sugerują, że proces wciąż zachowuje częściową strukturę sezonową. ACF nie zanika całkowicie i można wyróżnić kilka istotnie wykraczających poza granice przedziału ufności wartości autokorelacji. Oznacza to, że mimo usunięcia podstawowych komponentów, pozostaje wciąż pewna uporządkowana struktura. W rezultacie na podstawie wykresów na rysunku 27 możemy zasugerować, że szereg reszt z dekompozycji multiplikatywnej nie spełnia kryteriów stacjonarności.

3.6.3 Dekompozycja addytywna po transformacji Boxa-Coxa

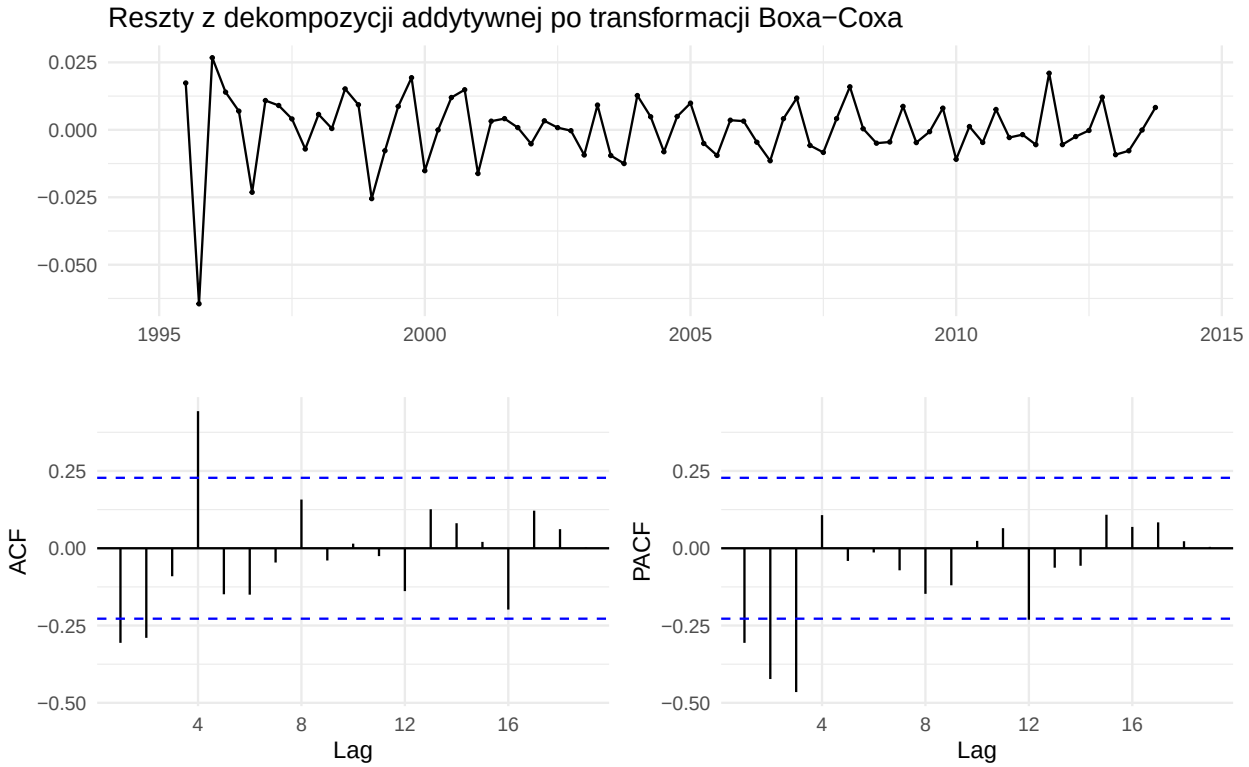

Rysunek 28: Diagnostyka reszt z dekompozycji addytywnej (po Box-Cox).

Wnioski w tym przypadku są analogiczne i bardzo podobne do tych z 3.6.2. Wykres reszt oraz ACF i PACF (rysunek 28) jest niemal identyczny jak w przypadku dekompozycji multiplikatywnej (rysunek 27). Podsumowując, kryteria stacjonarności nie zostały spełnione.

3.6.4 Dekompozycja na podstawie modelu regresji

W tym przypadku weźmy model o najdokładniejszym odwzorowaniu po transformacji Boxa-Coxa, czyli model regresji o trendzie postaci wielomianu trzeciego stopnia z sezonowością.

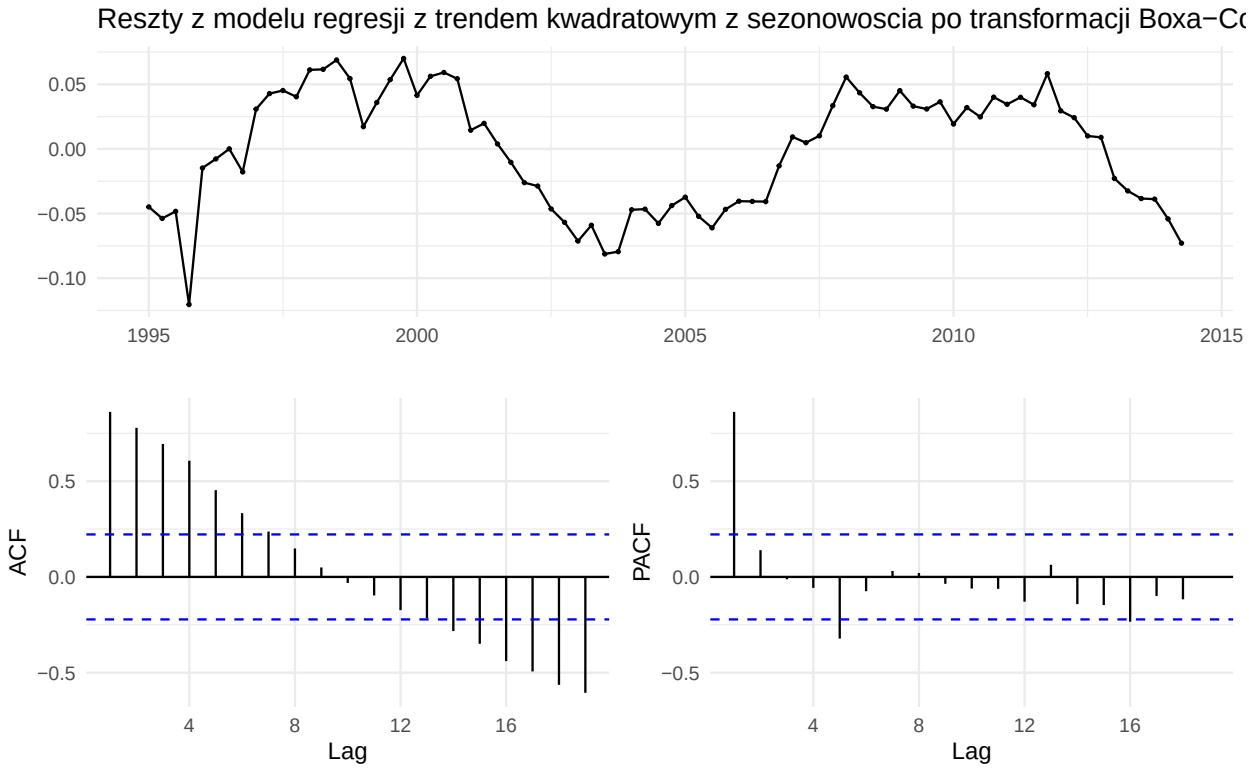

Rysunek 29: Diagnostyka reszt z modelu regresji (Trend Kwadratowy + Sezonowość, z Box-Cox).

Z wykresów na rysunku 29 zastosowanego na danych po transformacji Boxa-Coxa ($\lambda = 0$), wskazuje, że choć model ten bardzo dobrze dopasowuje się do szeregu, nie jest on wystarczający do osiągnięcia stacjonarności reszt. Na wykresie reszt widać, że oscylują one wokół zera, a wariancja jest stabilna. Najważniejszym dowodem na niestacjonarność jest analiza funkcji autokorelacji ACF: wartości przy niskich opóźnieniach znacząco przekraczają granice przedziału ufności, a co gorsza, widać wyraźny systematyczny spadek wartości ACF, oznaczający niewyeliminowany trend lub długookresową zależność, której model kwadratowy nie wychwycił. W rezultacie, szereg reszt nie jest więc stacjonarny.

3.6.5 Dekompozycja STL po transformacji Boxa-Coxa

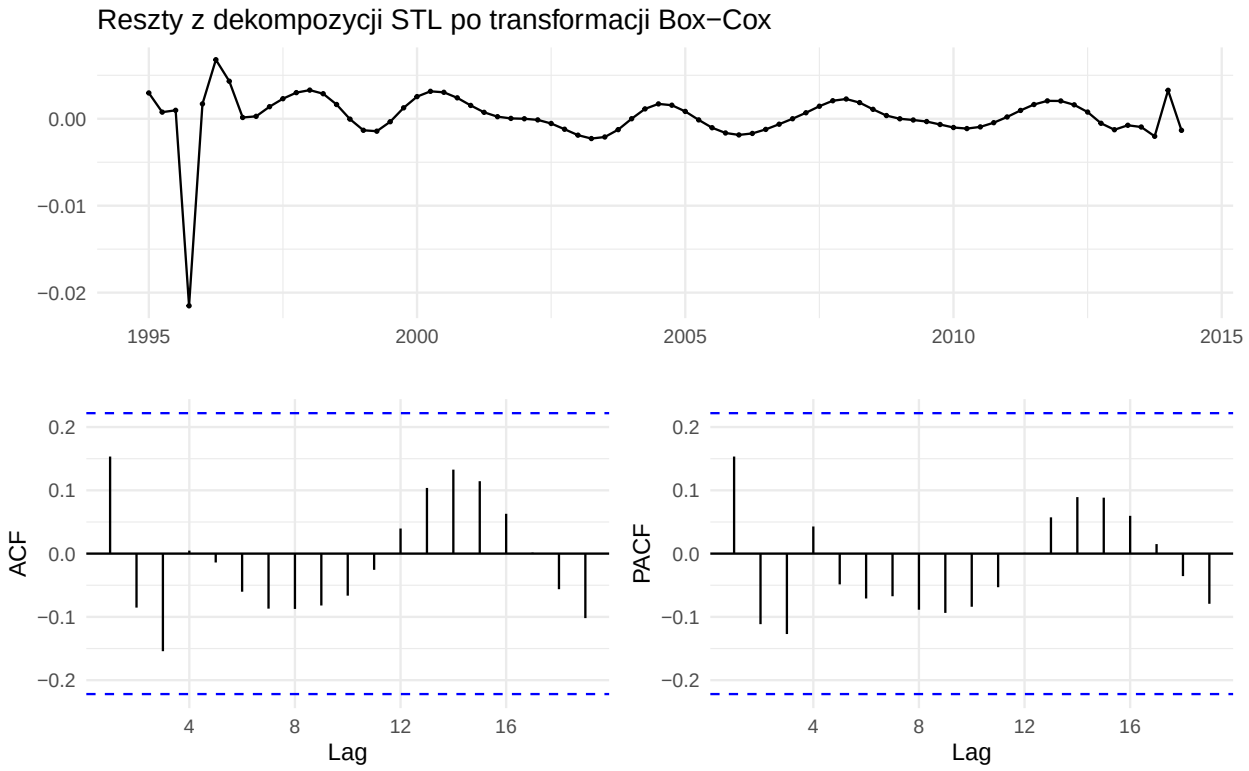

Rysunek 30: Diagnostyka reszt z dekompozycji STL (periodic, z Box-Cox).

Na wykresie reszt (rysunek 30) nie zaobserwowaliśmy żadnego systematycznego trendu ani wzorców sezonowych. Oscylacje są losowe i mają jednorodną wariancję. Funkcje autokorelacji ACF i PACF potwierdzają usunięcie zależności: autokorelacja szybko zanika do zera, a wszystkie słupki mieszczą się w granicach przedziału ufności. W rezultacie, szereg reszt z dekompozycji STL po transformacji Boxa-Coxa spełnia kryteria stacjonarności i jest bardzo bliski realizacji białego szumu, co czyni STL najbardziej skuteczną metodą dekompozycji do przygotowania danych PKB do dalszego modelowania.